Proyecto 2 – Data Mining

Semana 1: Comprensión del Problema y Análisis Exploratorio de Datos

Javier España Ángel Esquit Roberto Barreda Diego López

Abril 2026

Universidad del Valle de Guatemala

Curso: Data Mining | Dataset: Wisconsin Breast Cancer Dataset

Variable objetivo: `Class` (2 = Benigno, 4 = Maligno)

Índice

1. Contexto del Problema **2**

2. Descripción del Conjunto de Datos **2**

2.1. Dimensiones y estructura 2

2.2. Diccionario de variables 3

3. Análisis Exploratorio de Datos (EDA) **3**

3.1. Distribución de la variable objetivo 3

3.2. Estadísticas descriptivas por variable 4

3.3. Diferencia de medias por diagnóstico 5

3.4. Distribución de características por clase 5

3.5. Correlaciones entre variables y con la clase objetivo 7

3.6. Análisis de outliers por clase 8

3.7. Separabilidad visual: variables discriminativas clave 9

4. Plan de Acción Derivado del EDA **10**

5. Hipótesis para el Modelado **11**

6. Síntesis de Semana 1 **11**

1. Contexto del Problema

El cáncer de mama es la neoplasia maligna más frecuente en mujeres a nivel mundial. La detección temprana mediante biopsia por aspiración con aguja fina (FNA) es un procedimiento mínimamente invasivo que extrae células de una masa mamaria para evaluación citológica. El dataset de trabajo captura el resultado de ese proceso: cada registro representa una muestra analizada por un patólogo, con 9 características de morfología celular puntuadas en escala 1–10.

Problema a resolver: clasificación binaria supervisada para predecir si un tumor es **benigno** (Clase 2) o **maligno** (Clase 4) a partir de esas características. El fallo más costoso es el *falso negativo*: clasificar un tumor maligno como benigno puede retrasar el tratamiento con consecuencias graves. Esto condiciona todas las decisiones metodológicas del proyecto: la métrica principal de evaluación será el **Recall de la clase maligna**, no la exactitud global.

2. Descripción del Conjunto de Datos

El archivo `Datos.csv` proviene del *Wisconsin Breast Cancer Dataset* (Dr. William H. Wolberg, Universidad de Wisconsin), uno de los datasets de referencia en clasificación médica con aprendizaje automático.

2.1. Dimensiones y estructura

Cuadro 1: Resumen estructural del dataset original

Característica	**Valor**
Total de registros	683
Variables predictoras	9
Variable objetivo	1 (`Class`)
Identificador (no predictivo)	1 (`Sample code number`)
Total de columnas	11
Valores nulos	0
Registros duplicados	8
Rango de variables predictoras	1 – 10 (ordinal)

2.2. Diccionario de variables

Cuadro 2: Variables del dataset, tipo, rango e interpretación clínica

Variable	Tipo	Rango	Descripción / Significado clínico
Sample code number	ID entero	—	Identificador único de muestra; excluido del modelado
Clump Thickness	Ordinal	1–10	Grosor del grupo celular; mayor valor indica aglomeración anormal
Uniformity of Cell Size	Ordinal	1–10	Uniformidad de tamaño entre células; alta variabilidad es señal de malignidad
Uniformity of Cell Shape	Ordinal	1–10	Uniformidad de forma celular; morfología irregular asociada a malignidad
Marginal Adhesion	Ordinal	1–10	Adhesión al tejido circundante; células malignas tienden a desprenderse
Single Epithelial Cell Size	Ordinal	1–10	Tamaño de célula epitelial individual; agrandamiento celular es señal atípica
Bare Nuclei	Ordinal	1–10	Núcleos sin citoplasma visible; marcador fuerte de malignidad
Bland Chromatin	Ordinal	1–10	Textura de la cromatina nuclear; cromatina gruesa es indicador de malignidad
Normal Nucleoli	Ordinal	1–10	Tamaño y número de nucléolos; nucléolos prominentes indican actividad mitótica
Mitoses	Ordinal	1–10	Frecuencia de divisiones celulares; alta mitosis es criterio diagnóstico de malignidad
Class	Binaria	{2, 4}	**Variable objetivo**: 2 = Benigno, 4 = Maligno

3. Análisis Exploratorio de Datos (EDA)

3.1. Distribución de la variable objetivo

Se observó un **desbalance moderado** de clases: 65.0 % benignos frente a 35.0 % malignos.

Cuadro 3: Distribución de la variable objetivo

Clase	Frecuencia	Porcentaje
2 – Benigno	444	65.0 %
4 – Maligno	239	35.0 %
Total	683	100.0 %

Un clasificador ingenuo que predijera siempre "Benigno" obtendría un 65 % de exactitud, lo que demuestra que la *accuracy* sola es una métrica engañosa para este problema. **Decisión metodológica:** se usará `class_weight='balanced'` en los modelos lineales para compensar el desbalance. No se aplicará SMOTE porque el ratio 1.86:1 no es severo y se prioriza no introducir muestras sintéticas en un dataset pequeño con datos clínicos reales.

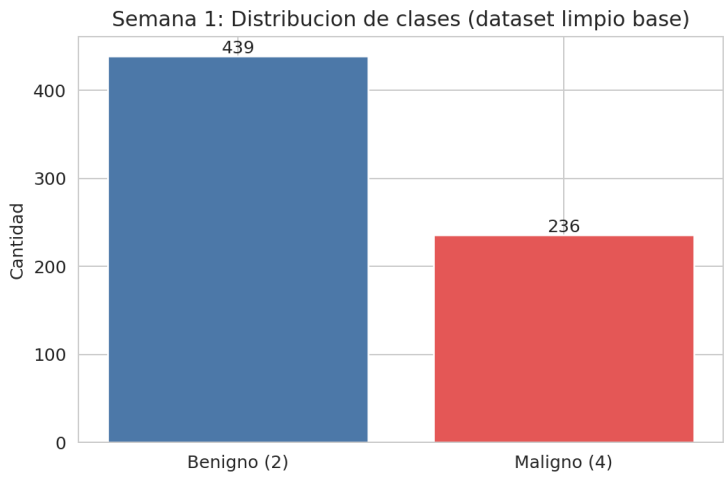

Figura 1: Distribución de clases en el dataset. El desbalance moderado (1.86:1) condiciona la selección de métricas de evaluación.

3.2. Estadísticas descriptivas por variable

Cuadro 4: Estadísticas descriptivas de las variables predictoras (683 registros)

Variable	**Media**	**Desv. Est.**	**Min**	**Q1**	**Mediana**	**Q3**	**Max**
Clump Thickness	4.44	2.82	1	2	4	6	10
Uniformity of Cell Size	3.15	3.07	1	1	1	5	10
Uniformity of Cell Shape	3.22	2.99	1	1	1	5	10
Marginal Adhesion	2.83	2.86	1	1	1	4	10
Single Epithelial Cell Size	3.23	2.22	1	2	2	4	10
Bare Nuclei	3.54	3.64	1	1	1	6	10
Bland Chromatin	3.45	2.45	1	2	3	5	10
Normal Nucleoli	2.87	3.05	1	1	1	4	10
Mitoses	1.60	1.73	1	1	1	1	10

Las medianas bajas (Q2 = 1 en la mayoría de variables) reflejan que la mayor parte de la distribución corresponde a casos benignos. La alta desviación estándar en variables como `Bare Nuclei` (3.64) y `Uniformity of Cell Size` (3.07) anticipa que existirá separación significativa entre clases.

3.3. Diferencia de medias por diagnóstico

Cuadro 5: Media por variable según clase diagnóstica y diferencia absoluta

Variable	**Benigno (media)**	**Maligno (media)**	**Δ (Mal − Ben)**
Bare Nuclei	1.35	7.63	**+6.28**
Uniformity of Cell Size	1.31	6.58	**+5.27**
Uniformity of Cell Shape	1.41	6.56	**+5.15**
Clump Thickness	2.96	7.19	+4.23
Marginal Adhesion	1.35	5.59	+4.24
Normal Nucleoli	1.26	5.86	+4.60
Bland Chromatin	2.08	5.97	+3.89
Single Epithelial Cell Size	2.11	5.33	+3.22
Mitoses	1.07	2.60	+1.53

Las tres variables con mayor diferencia de medias (`Bare Nuclei`, `Uniformity of Cell Size` y `Uniformity of Cell Shape`) son precisamente las más correlacionadas con la clase objetivo. `Mitoses` muestra la menor diferencia y es, consistentemente, la variable menos discriminativa del dataset.

3.4. Distribución de características por clase

Los histogramas por diagnóstico confirman el patrón observado en las medias: **los casos benignos se concentran fuertemente en valores bajos (1–3)**, mientras que los malignos presentan distribuciones más dispersas y sesgadas hacia valores altos.

figures/s1_histogramas_por_clase.png

Figura 2: Distribución de cada variable predictora segmentada por diagnóstico (verde = Benigno, rojo = Maligno). Las tres primeras variables del panel superior muestran la separación más marcada.

Un fenómeno relevante es el **efecto techo**: varias variables malignas acumulan observaciones en el valor máximo (10). Esto indica que la escala puede ser insuficiente para representar casos extremos y que algunos outliers son casos clínicamente severos, no errores de medición.

3.5. Correlaciones entre variables y con la clase objetivo

Cuadro 6: Correlación de Pearson de cada variable predictora con `Class` (ordenado por valor absoluto)

Variable	r **con Class**	**Relevancia**
Bare Nuclei	0.823	Alta
Uniformity of Cell Shape	0.822	Alta
Uniformity of Cell Size	0.821	Alta
Bland Chromatin	0.758	Alta
Normal Nucleoli	0.719	Alta
Clump Thickness	0.715	Alta
Marginal Adhesion	0.706	Alta
Single Epithelial Cell Size	0.691	Moderada–Alta
Mitoses	0.423	Moderada

Todas las variables tienen correlación positiva con la clase (mayor valor = mayor probabilidad de malignidad). Destaca que **8 de 9 variables tienen** $|r| > 0{,}69$, lo que anticipa un problema bien condicionado para clasificación.

Multicolinealidad detectada: Se identificaron múltiples pares de variables con correlación superior a 0.70 entre sí, siendo el caso más severo el par `Uniformity of Cell Size` – `Uniformity of Cell Shape` ($r = 0{,}907$). La tabla siguiente muestra todos los pares problemáticos:

Cuadro 7: Pares de variables predictoras con correlación alta ($|r| \geq 0{,}70$)

Variable 1	**Variable 2**	r
Uniformity of Cell Size	Uniformity of Cell Shape	**0.907**
Uniformity of Cell Size	Bland Chromatin	0.756
Uniformity of Cell Size	Single Epithelial Cell Size	0.754
Uniformity of Cell Size	Normal Nucleoli	0.719
Uniformity of Cell Size	Marginal Adhesion	0.707
Uniformity of Cell Shape	Bland Chromatin	0.735
Uniformity of Cell Shape	Normal Nucleoli	0.718
Uniformity of Cell Shape	Single Epithelial Cell Size	0.722
Uniformity of Cell Shape	Bare Nuclei	0.714

Decisión metodológica ante la colinealidad: se abordarán en Semana 2 mediante tres estrategias complementarias: (i) regularización L2 en Regresión Logística para estabilizar coeficientes; (ii) comparación entre Escenario A (todas las variables) y Escenario B (solo las top-3 correlacionadas con la clase), midiendo si la redundancia informativa realmente perjudica el desempeño; (iii) se evaluó PCA como alternativa pero se descartó para preservar interpretabilidad clínica de las variables originales.

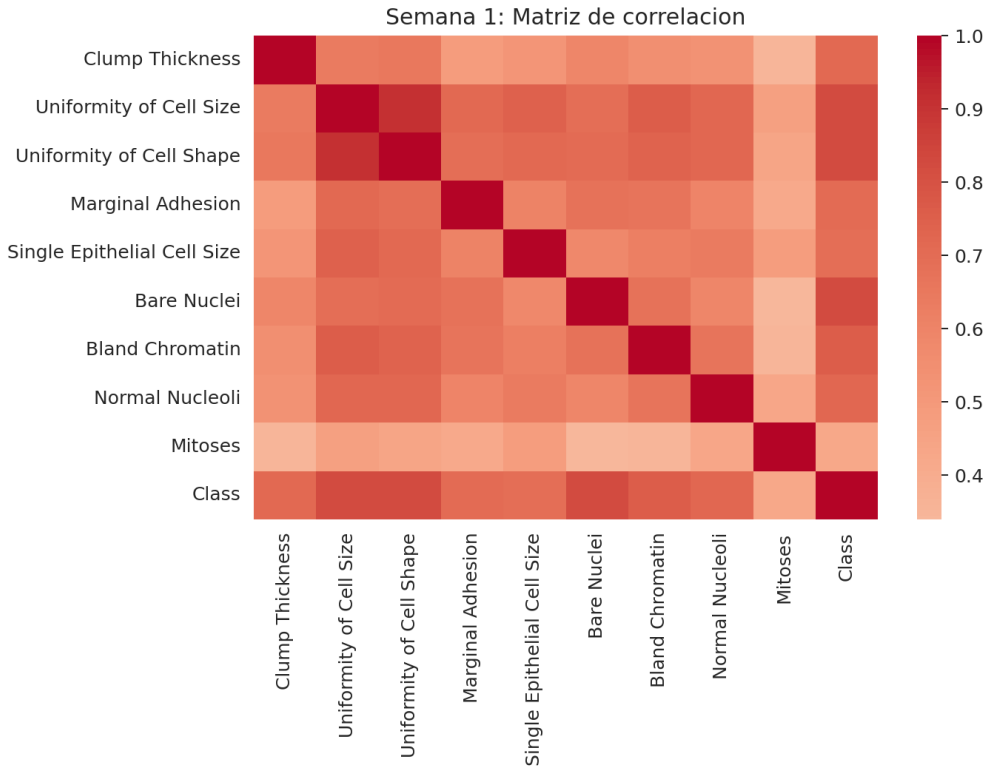

Figura 3: Matriz de correlación entre variables predictoras y variable objetivo. La esquina superior izquierda (variables de uniformidad) concentra la mayor colinealidad inter-variable.

3.6. Análisis de outliers por clase

Los outliers se calcularon aplicando el criterio IQR *dentro de cada clase por separado*, evitando contaminar el umbral de normalidad de una clase con la distribución de la otra.

Cuadro 8: Conteo de outliers por variable y clase (IQR calculado dentro de cada clase)

Variable	**Benigno (n=444)**		**Maligno (n=239)**	
	N outliers	**%**	**N outliers**	**%**
Uniformity of Cell Shape	100	22.5 %	0	0.0 %
Single Epithelial Cell Size	89	20.0 %	0	0.0 %
Marginal Adhesion	81	18.2 %	0	0.0 %
Uniformity of Cell Size	75	16.9 %	0	0.0 %
Bare Nuclei	57	12.8 %	0	0.0 %
Normal Nucleoli	53	11.9 %	0	0.0 %
Mitoses	13	2.9 %	29	12.1 %
Bland Chromatin	6	1.4 %	0	0.0 %

Interpretación: los outliers en la clase benigna corresponden a casos que, aun siendo benignos, presentan valores atípicamente altos en algunas variables citológicas. Son clínicamente plausibles (tumores benignos con rasgos atípicos). En la clase maligna, únicamente `Mitoses` genera outliers significativos (29, 12.1 %), consistente con la conocida relación entre alta actividad mitótica y tumores agresivos.

Decisión metodológica: no se eliminarán outliers de forma automática. Representan información clínica real que los modelos deben aprender a clasificar. Eliminarlos distorsionaría la distribución de los datos de entrenamiento.

`figures/s1_boxplots_por_clase.png`

Figura 4: Boxplots por diagnóstico de las 9 variables predictoras. Los puntos fuera de los bigotes representan outliers dentro de cada clase. La distribución de la clase maligna es visiblemente más dispersa en casi todas las variables.

3.7. Separabilidad visual: variables discriminativas clave

El análisis de las tres variables más correlacionadas con la clase (`Bare Nuclei`, `Uniformity of Cell Size`, `Uniformity of Cell Shape`) confirma fronteras de decisión visualmente claras:

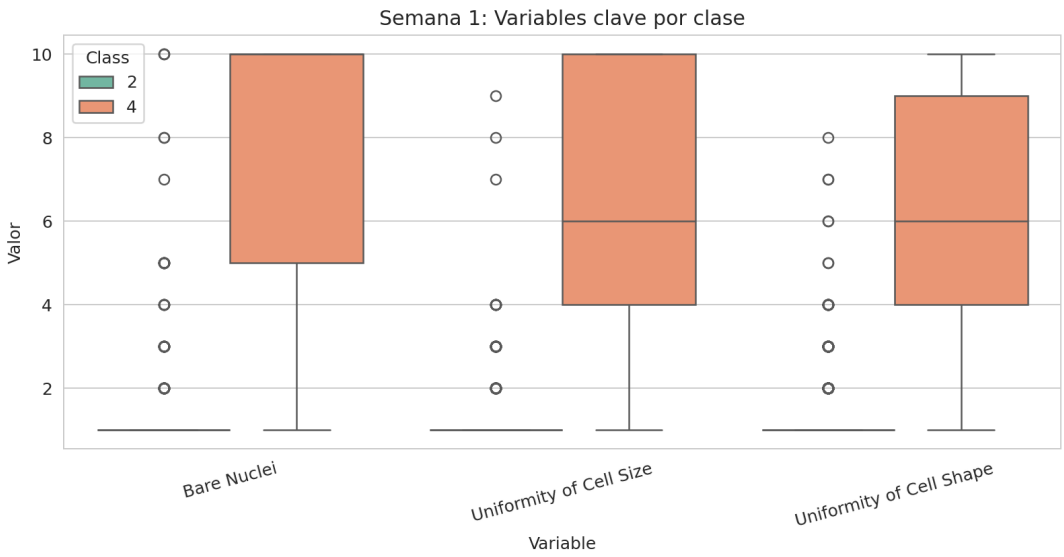

Figura 5: Distribución de las tres variables más discriminativas por diagnóstico. Las medianas de la clase maligna son consistentemente entre 4 y 6 puntos más altas que las de la clase benigna.

Decisión metodológica: esta separabilidad respalda el uso de modelos con fronteras de decisión bien definidas (Regresión Logística y SVM). KNN se incluye como baseline no paramétrico para validar que la separabilidad no sea artefacto de un supuesto específico de distribución.

4. Plan de Acción Derivado del EDA

Cada hallazgo del EDA se traduce directamente en una decisión de diseño para Semana 2:

Cuadro 9: Mapa hallazgos EDA → decisiones de modelado

Hallazgo EDA	**Implicación técnica**	**Acción en Semana 2**
Separabilidad marcada por clase	Fronteras de decisión deben funcionar bien	Entrenar LR, KNN y SVM; esperar buen desempeño de todos
Colinealidad alta ($r = 0{,}91$)	Riesgo de inestabilidad en modelos lineales	L2 en LR; Escenario B (top-3 variables) como prueba de robustez
Desbalance 65/35	Accuracy no es métrica confiable	`class_weight='balanced'`; priorizar Recall de maligna
Outliers clínicos en clase maligna	No son ruido; contienen información real	Conservar outliers; no aplicar limpieza agresiva
Mitoses poco discriminativa	Puede añadir ruido	Evaluar en Escenario B si su exclusión mejora estabilidad

5. Hipótesis para el Modelado

Con base en el EDA, se establecen las siguientes hipótesis verificables en las semanas posteriores:

H1. `Bare Nuclei`, `Uniformity of Cell Size` y `Uniformity of Cell Shape` serán las features más importantes en cualquier modelo entrenado.

H2. Modelos no lineales (SVM-RBF) capturarán mejor las relaciones del espacio de variables que modelos puramente lineales.

H3. El Recall de la clase maligna debe ser la métrica de optimización principal, no la exactitud global.

H4. La multicolinealidad entre variables de uniformidad puede desestabilizar modelos lineales sin regularización.

H5. Los outliers clínicamente identificados (especialmente en `Mitoses` de la clase maligna) deben conservarse; eliminarlos perjudicaría el aprendizaje de casos agresivos.

6. Síntesis de Semana 1

El EDA revela un dataset bien estructurado, sin valores nulos en variables predictoras y con separabilidad alta entre clases. Los hallazgos clave son tres: (1) las variables de uniformidad celular y los núcleos desnudos son los discriminadores más fuertes; (2) existe colinealidad considerable dentro del grupo de variables de uniformidad; y (3) el desbalance moderado exige estrategias de compensación y métricas centradas en la clase maligna.

El valor principal de esta semana no es descriptivo sino de diseño: cada hallazgo del EDA queda mapeado a una decisión concreta que condicionará el modelado de Semana 2 y la evaluación de Semana 3.

Repositorio del proyecto: https://github.com/AngelEsquit/PRY2-MD.git