Proyecto 2 – Data Mining

Semana 2: Preparación de Datos y Modelos Base

Javier España Ángel Esquit Roberto Barreda Diego López

Abril 2026

Universidad del Valle de Guatemala

Curso: Data Mining | Dataset: Wisconsin Breast Cancer Dataset

Variable objetivo: `Class` (2 = Benigno, 4 = Maligno)

Índice

1. Objetivo de Semana 2 **2**

2. Preprocesamiento de Datos **2**

2.1. Diagnóstico del dataset original 2

2.2. Pasos de limpieza aplicados 2

2.3. Partición train / test 3

3. Escenarios de Variables **3**

4. Modelos Base **5**

4.1. Regresión Logística (LR) 5

4.2. K-Nearest Neighbors (KNN, k=5) 5

4.3. SVM con kernel RBF 5

5. Resultados: Escenario A (Todas las variables) **5**

6. Resultados: Escenario B (Top 3 variables) **7**

7. Comparación Cruzada A vs B **8**

8. Conclusiones de Semana 2 **8**

1. Objetivo de Semana 2

Con base en los hallazgos del EDA de Semana 1, esta fase tuvo tres objetivos concretos: (1) convertir el dataset crudo en un dataset de modelado limpio y trazable; (2) implementar dos escenarios de variables como respuesta directa al hallazgo de colinealidad; y (3) establecer una línea base de rendimiento con tres modelos sin optimizar, usando las métricas prioritarias definidas en el EDA.

2. Preprocesamiento de Datos

2.1. Diagnóstico del dataset original

Se partió de `Datos.csv` con 683 registros y 11 columnas. Antes de entrenar cualquier modelo se realizó un diagnóstico sistemático del estado del dataset:

Cuadro 1: Diagnóstico del dataset original antes de limpieza

Problema detectado	**Descripción**	**Conteo**
Registros duplicados exactos	Filas idénticas en todas las columnas	8
Identificador no predictivo	`Sample code number` sin valor para modelado	1 columna
Valores fuera de rango (predictoras)	Valores < 1 o > 10 en variables 1–10	0
Valores nulos directos	`NaN` o `None` en cualquier columna	0

Nota sobre `Bare Nuclei`: en la versión estándar del Wisconsin Breast Cancer Dataset publicada en UCI, esta variable contiene 16 valores codificados como `"?"`. En el presente dataset (`Datos.csv`), la columna ya viene limpia con valores numéricos válidos en el rango 1–10. Sin embargo, el pipeline de limpieza incluyó la detección y tratamiento de esos marcadores por robustez, por si aparecieran en re-ejecuciones con datos externos.

2.2. Pasos de limpieza aplicados

1. **Eliminación de duplicados:** se identificaron y removieron 8 filas duplicadas exactas.
2. **Detección de marcadores inválidos:** búsqueda de valores `"?"` en todas las columnas; ninguno encontrado en este dataset.
3. **Verificación de rangos:** todas las variables predictoras confirmadas en el rango 1–10.
4. **Exclusión de identificador:** `Sample code number` excluido por no tener valor predictivo.
5. **Exportación:** se generó `Datos_modelado.csv` como dataset oficial para modelado.

Cuadro 2: Comparación dataset original vs dataset de modelado

Característica	**Original (`Datos.csv`)**	**Modelado (`Datos_modelado.csv`)**	**Diferencia**
Registros	683	675	−8 (duplicados)
Columnas	11	10	−1 (ID excluido)
Variables predictoras	9	9	Sin cambio
Valores nulos	0	0	Sin cambio

2.3. Partición train / test

Se utilizó partición estratificada 80/20 con `random_state=42` para garantizar reproducibilidad y preservar la proporción de clases en ambos conjuntos:

Cuadro 3: Distribución de muestras y clases en la partición

Partición	**Total**	**Benigno (2)**	**Maligno (4)**	**Ratio Ben/Mal**
Completo	675	439 (65.0 %)	236 (35.0 %)	1.86:1
Entrenamiento	540	351 (65.0 %)	189 (35.0 %)	1.86:1
Prueba	135	88 (65.2 %)	47 (34.8 %)	1.87:1

La diferencia máxima de proporciones entre particiones es de 0.2 puntos porcentuales, confirmando que la estratificación funcionó correctamente.

3. Escenarios de Variables

Se definieron dos escenarios de variables como respuesta directa a los hallazgos de colinealidad del EDA:

Cuadro 4: Definición de los escenarios de variables y su justificación

Escenario	**Variables incluidas**	**Justificación**
A – Todas	9 variables citológicas	Baseline completo; permite que los modelos aprovechen toda la información disponible
B – Top 3	`Bare Nuclei`, `Uniformity of Cell Size`, `Uniformity of Cell Shape`	Respuesta directa a la colinealidad ($r = 0{,}91$) detectada en Semana 1. Mide si el subconjun-

Sobre PCA: se evaluó como alternativa para manejar la colinealidad, pero se descartó en esta etapa por tres razones: (i) solo hay 9 variables originales, lo que limita la compresión significativa; (ii) se priorizó interpretabilidad clínica de variables observables; (iii) la estrategia L2 + comparación A/B permite controlar la colinealidad sin perder trazabilidad de cada rasgo citológico. Si el rendimiento en Semana 3 no fuera satisfactorio, PCA quedaría como alternativa para Semana 4.

4. Modelos Base

Se entrenaron tres modelos sin optimización de hiperparámetros para establecer una línea de referencia. Todos usan `StandardScaler` dentro de un `Pipeline` para evitar fuga de información.

4.1. Regresión Logística (LR)

Modelo lineal de referencia para clasificación binaria. La regularización L2 por defecto (`C=1.0`) se usó *deliberadamente* como respuesta técnica al riesgo de colinealidad identificado en el EDA: el término de penalización estabiliza los coeficientes cuando las variables son altamente correlacionadas, evitando que pequeñas perturbaciones en los datos generen cambios grandes en los pesos del modelo.

Parámetros base: `solver='lbfgs'`, `penalty='l2'`, `C=1.0`, `class_weight='balanced'`.

4.2. K-Nearest Neighbors (KNN, k=5)

Clasificador no paramétrico basado en distancia. No asume ninguna forma funcional para la frontera de decisión, lo que lo hace útil como punto de comparación cuando la distribución real de los datos es incierta. Requiere escalado de variables (realizado en el pipeline). Se usó $k = 5$ como baseline estándar.

Parámetros base: `n_neighbors=5`, `weights='uniform'`, `metric='minkowski'`.

4.3. SVM con kernel RBF

Modelo no lineal basado en maximización de margen. Se eligió por dos razones derivadas del EDA: (1) la alta separabilidad visual entre clases sugería que una frontera de margen máximo sería eficiente; (2) el kernel RBF permite capturar relaciones no lineales en el espacio de variables sin imponer forma funcional explícita. Adicionalmente, SVM es intrínsecamente robusto frente a outliers por construcción (solo los vectores de soporte influyen en la frontera).

Parámetros base: `C=1.0`, `gamma='scale'`, `kernel='rbf'`, `class_weight='balanced'`.

5. Resultados: Escenario A (Todas las variables)

Las métricas de precisión, recall y F1 se reportan para la clase positiva (maligna, `Class=4`).

Cuadro 5: Métricas de modelos base – Escenario A (todas las variables, conjunto de prueba)

Modelo	**Accuracy**	**Precision**	**Recall**	**F1-Score**	**FN**
Regresión Logística	0.9556	0.9362	0.9362	0.9362	3
KNN (k=5)	0.9556	0.9362	0.9362	0.9362	3
SVM (RBF)	**0.9630**	**0.9375**	**0.9574**	**0.9474**	**2**

Cuadro 6: Matrices de confusión – Escenario A (clase positiva = Maligno)

Modelo	**TN**	**FP**	**FN**	**TP**	**Total test**
Regresión Logística	85	3	3	44	135
KNN (k=5)	85	3	3	44	135
SVM (RBF)	85	3	2	45	135

Lectura: los tres modelos tienen exactamente los mismos FP (3), pero SVM reduce los FN de 3 a 2, lo que se traduce directamente en un recall más alto. Esta diferencia, aunque pequeña en términos absolutos (1 caso), es clínicamente relevante: representa un paciente con cáncer que hubiera sido clasificado incorrectamente como benigno.

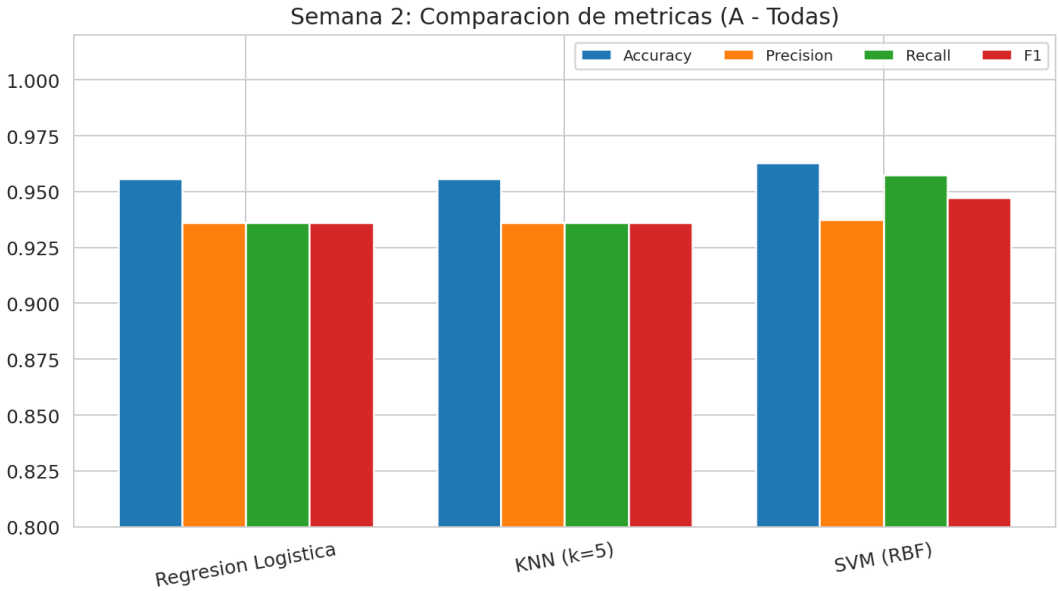

Figura 1: Comparación visual de métricas en Escenario A. SVM supera levemente a LR y KNN en Recall y F1; los tres modelos tienen idéntico AUC de 0.99+.

6. Resultados: Escenario B (Top 3 variables)

Cuadro 7: Métricas de modelos base – Escenario B (top 3 variables, conjunto de prueba)

Modelo	Accuracy	Precision	Recall	F1-Score	FN
Regresión Logística	0.9259	0.9302	0.8511	0.8889	7
KNN (k=5)	0.9481	0.9348	0.9149	0.9247	4
SVM (RBF)	0.9481	0.9348	0.9149	0.9247	4

Cuadro 8: Matrices de confusión – Escenario B

Modelo	TN	FP	FN	TP	Total test
Regresión Logística	82	6	7	40	135
KNN (k=5)	85	3	4	43	135
SVM (RBF)	85	3	4	43	135

Hallazgo clave: la reducción a 3 variables afecta de forma muy distinta a cada modelo. LR sufre una caída dramática en recall (de 93.6 % a 85.1 %) y sus FN se triplican (de 3 a 7). KNN y SVM, en cambio, degradan de forma mucho más controlada. Esto confirma que la colinealidad afecta principalmente a LR porque perder variables redundantes pero informativas desestabiliza sus coeficientes.

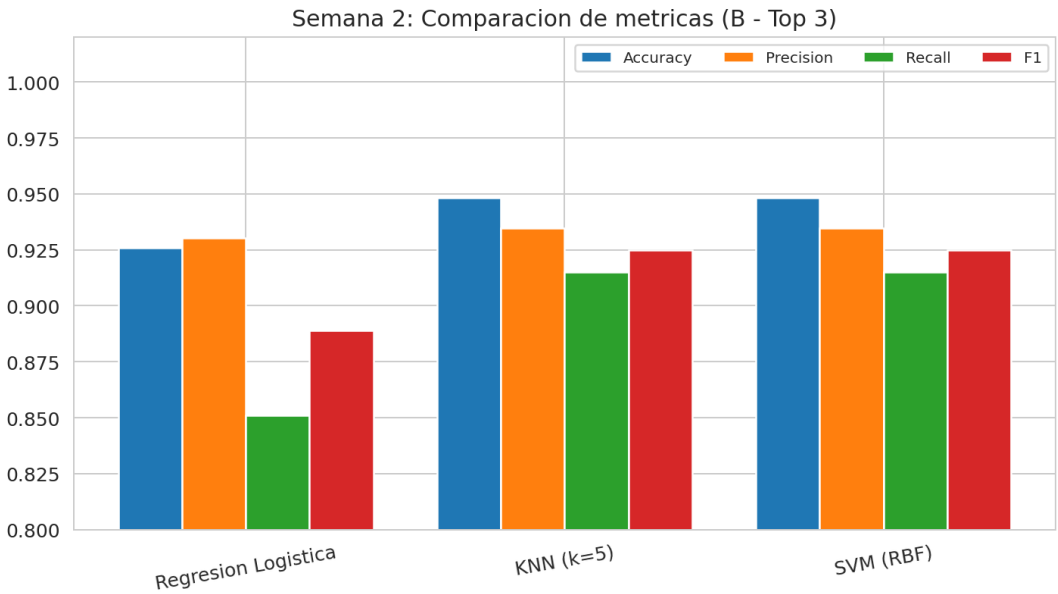

Figura 2: Comparación visual de métricas en Escenario B. La caída de LR en Recall es notablemente mayor que la de KNN y SVM.

7. Comparación Cruzada A vs B

Cuadro 9: Impacto de la reducción de variables (A → B) en Recall de clase maligna y FN

Modelo	**Recall A**	**Recall B**	**Δ Recall**	**Δ FN**
Regresión Logística	0.9362	0.8511	−0.0851	+4
KNN (k=5)	0.9362	0.9149	−0.0213	+1
SVM (RBF)	0.9574	0.9149	−0.0425	+2

El patrón es consistente: todos los modelos pierden recall al reducir variables, pero LR pierde 4 veces más que KNN. Esto tiene dos implicaciones para Semana 3:

1. El **Escenario A** es el candidato principal para la optimización final, ya que sostiene mejor rendimiento en todos los modelos.
2. LR necesitará **tuning de regularización** para estabilizarse, especialmente si se expande el espacio de hiperparámetros más allá del valor por defecto ($C = 1{,}0$).

8. Conclusiones de Semana 2

1. El dataset fue limpiado de forma trazable: 8 duplicados eliminados, identificador excluido, 675 registros finales.
2. **SVM con kernel RBF** es el mejor modelo base en Escenario A, con el mayor Recall (0.9574) y el menor número de falsos negativos (2).
3. LR y KNN empatan en Escenario A, pero LR es más sensible a la reducción de variables, lo que confirma el riesgo de colinealidad identificado en Semana 1.
4. El Escenario A supera al B en todos los modelos. Escenario B no es un fracaso: evidencia que con solo 3 variables ya se obtiene 91–93 % de recall, lo que cuantifica el poder predictivo del subconjunto discriminativo.
5. La hipótesis H3 (Recall como métrica principal) queda reforzada: un modelo con accuracy de 95.6 % puede aún tener 3 falsos negativos clínicamente críticos.
6. La hipótesis H4 (impacto de colinealidad en LR) queda confirmada: LR es el modelo más afectado por la reducción de variables.

Repositorio del proyecto: https://github.com/AngelEsquit/PRY2-MD.git