Proyecto 2 – Data Mining

Semana 3: Validación, Optimización y Selección Final de Modelo

Javier España Ángel Esquit Roberto Barreda Diego López

Abril 2026

Universidad del Valle de Guatemala

Curso: Data Mining | Dataset: Wisconsin Breast Cancer Dataset

Variable objetivo: `Class` (2 = Benigno, 4 = Maligno)

Índice

1. Objetivo de Semana 3 **2**

2. Diseño Experimental **2**

2.1. Dataset y split 2

2.2. Esquema de validación cruzada 2

2.3. Control de fuga de información 2

3. Validación Base Pre-Tuning **3**

3.1. Resultados de validación cruzada – Escenario A 3

3.2. Resultados de validación cruzada – Escenario B 3

3.3. Consistencia CV vs Test (base) 3

4. Optimización de Hiperparámetros: LR y KNN **3**

4.1. Metodología 3

4.2. Mejores hiperparámetros encontrados 4

4.3. Comparación base vs optimizado: LR y KNN 4

4.4. Diagnóstico de ajuste – LR y KNN 5

5. Optimización de Hiperparámetros: SVM **5**

5.1. Espacio de búsqueda 5

5.2. Mejores configuraciones SVM 5

5.3. Resultado central: base vs optimizado 6

5.4. Diagnóstico de ajuste – SVM 6

6. Comparación Final: Todos los Modelos Optimizados **6**

7. Modelo Final Seleccionado **7**

7.1. Selección 7

7.2. Justificación técnica 7

7.3. Cuantificación del trade-off clínico 7

8. Sesgo, Varianza y Estabilidad del Modelo Final **8**

9. Verificación de Hipótesis de Semana 1 **10**

10. Conclusiones de Semana 3 **11**

1. Objetivo de Semana 3

Esta semana cerró el ciclo experimental del proyecto con cuatro frentes: (1) validación cruzada rigurosa y comparable de los tres modelos base; (2) optimización de hiperparámetros mediante `GridSearchCV` con la métrica clínica correcta; (3) diagnóstico de ajuste (sobreajuste vs. subajuste); y (4) selección formal del modelo final con justificación técnica explícita y cuantificación de trade-offs.

La métrica principal de toda esta semana fue el **Recall de la clase maligna** (`Class=4`), establecida desde el EDA de Semana 1 por el costo clínico de los falsos negativos.

2. Diseño Experimental

2.1. Dataset y split

Se trabajó con `Datos_modelado.csv` (675 registros, 9 variables predictoras + `Class`), heredado de Semana 2 sin modificaciones para preservar comparabilidad. El split 80/20 estratificado con `random_state=42` se mantuvo idéntico.

Cuadro 1: Verificación de proporciones de clase a lo largo del experimento

Clase	**Total**	**Train**	**Test**
Benigna (2)	65.04 %	65.00 %	65.19 %
Maligna (4)	34.96 %	35.00 %	34.81 %

La diferencia máxima entre particiones es 0.19 pp, confirmando que la estratificación no introduce sesgo de distribución.

2.2. Esquema de validación cruzada

Se adoptó **5-Fold Stratified Cross-Validation** (`StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`) como método de validación. Este esquema garantiza:

- Proporción de clases preservada en cada fold (crítico dado el desbalance 65/35).
- Cinco estimaciones independientes del rendimiento, reduciendo la varianza del estimador.
- Comparabilidad entre modelos: todos usan exactamente el mismo protocolo de folds.

2.3. Control de fuga de información

Todas las transformaciones (escalado con `StandardScaler`) se encapsulan dentro de un `sklearn.Pipeline`. Esto garantiza que el scaler se ajusta únicamente con los datos de entrenamiento de cada fold y nunca ve los datos de validación o de prueba, eliminando el riesgo de *data leakage*.

3. Validación Base Pre-Tuning

3.1. Resultados de validación cruzada – Escenario A

Cuadro 2: Cross-validation base en Escenario A (media ± desviación estándar, 5 folds)

Modelo	**Accuracy**	**Recall macro**	**F1**	**AUC**
Regresión Logística	$0{,}9704 \pm 0{,}0283$	$0{,}9664 \pm 0{,}0351$	$0{,}9702 \pm 0{,}0287$	$0{,}9941 \pm 0{,}0074$
KNN (k=5)	$0{,}9685 \pm 0{,}0224$	$0{,}9636 \pm 0{,}0272$	$0{,}9684 \pm 0{,}0226$	$0{,}9843 \pm 0{,}0262$
SVM (RBF)	$0{,}9611 \pm 0{,}0312$	$0{,}9617 \pm 0{,}0341$	$0{,}9613 \pm 0{,}0312$	$0{,}9898 \pm 0{,}0109$

3.2. Resultados de validación cruzada – Escenario B

Cuadro 3: Cross-validation base en Escenario B (top 3 variables)

Modelo	**Accuracy**	**Recall macro**	**F1**	**AUC**
Regresión Logística	$0{,}9648 \pm 0{,}0271$	$0{,}9583 \pm 0{,}0305$	$0{,}9647 \pm 0{,}0272$	$0{,}9912 \pm 0{,}0112$
KNN (k=5)	$0{,}9667 \pm 0{,}0239$	$0{,}9634 \pm 0{,}0246$	$0{,}9667 \pm 0{,}0237$	$0{,}9823 \pm 0{,}0167$
SVM (RBF)	$0{,}9574 \pm 0{,}0319$	$0{,}9538 \pm 0{,}0339$	$0{,}9575 \pm 0{,}0317$	$0{,}9880 \pm 0{,}0122$

3.3. Consistencia CV vs Test (base)

Cuadro 4: Coherencia entre validación cruzada y conjunto de prueba – modelos base

Modelo	**Esc.**	**Acc CV**	**Acc Test**	**Gap Acc**	**Gap Recall**
Regresión Logística	A	0.9704	0.9556	-0.0148	-0.0153
KNN	A	0.9685	0.9556	-0.0130	-0.0126
SVM	A	0.9611	0.9630	$+0.0019$	≈ 0
Regresión Logística	B	0.9648	0.9259	-0.0389	-0.0498
KNN	B	0.9667	0.9481	-0.0185	-0.0230
SVM	B	0.9574	0.9481	-0.0093	-0.0134

El gap más grande lo muestra LR en Escenario B (-0.0498 en Recall), consistente con la caída observada en Semana 2. En Escenario A todos los gaps son menores a 0.016, lo que indica generalización estable y habilita una etapa de tuning confiable.

4. Optimización de Hiperparámetros: LR y KNN

4.1. Metodología

Se ejecutó `GridSearchCV` con el mismo `StratifiedKFold(5)` y como métrica de selección el **Recall de la clase maligna** (`pos_label=4`). El test set no participó en ninguna decisión de tuning.

4.2. Mejores hiperparámetros encontrados

Cuadro 5: Mejores hiperparámetros de LR y KNN por escenario

Esc.	Modelo	Best Recall CV	Std	Mejores parámetros
A	LR	0.9789	0.0421	`C=0.1, penalty=l1, solver=liblinear, class_weight=balanced`
A	KNN	0.9632	0.0488	`n_neighbors=9, weights=uniform, metric=euclidean`
B	LR	0.9471	0.0333	`C=3, penalty=l2, solver=lbfgs, class_weight=balanced`
B	KNN	0.9578	0.0268	`n_neighbors=7, weights=uniform, metric=euclidean`

Observaciones sobre LR: el mejor C en Escenario A es 0.1 (alta regularización), lo que confirma que el modelo se beneficia de penalización fuerte cuando trabaja con variables colineales. En Escenario B, el mejor C es 3 (menor regularización), pues con solo 3 variables hay menos redundancia que penalizar.

4.3. Comparación base vs optimizado: LR y KNN

Cuadro 6: Impacto del tuning en Recall de maligna y FN – LR y KNN

Esc.	Modelo	Tipo	Recall CV	Recall Test	FN test	Δ FN
A	LR	Base	0.9526	0.9362	3	−1
	LR	Optimizado	0.9789	0.9574	2	
	KNN	Base	0.9472	0.9362	3	+1
	KNN	Optimizado	0.9632	0.9149	4	
B	LR	Base	0.9366	0.8511	7	−3
	LR	Optimizado	0.9471	0.9149	4	
	KNN	Base	0.9525	0.9149	4	0
	KNN	Optimizado	0.9578	0.9149	4	

Hallazgo crítico: el tuning de KNN en Escenario A *empeora* el recall en test (-0.0213) y aumenta los FN de 3 a 4. Esto indica que los hiperparámetros encontrados en validación no se transfieren bien a test para KNN, lo que descalifica a KNN como candidato final.

4.4. Diagnóstico de ajuste – LR y KNN

Cuadro 7: Análisis de sobreajuste/subajuste – modelos optimizados LR y KNN

Esc.	Modelo	Recall train	Recall valid	Gap	Diagnóstico
A	LR	0.9841	0.9789	0.0052	Estable
A	KNN	0.9643	0.9632	0.0011	Estable
B	LR	0.9471	0.9471	0.0000	Estable
B	KNN	0.9630	0.9578	0.0052	Estable

Los gaps train-valid son mínimos en todos los modelos. Sin embargo, KNN en Escenario A exhibe una discordancia entre la estabilidad en CV y la caída en test, lo que sugiere sensibilidad a la distribución específica del fold o del test set.

5. Optimización de Hiperparámetros: SVM

5.1. Espacio de búsqueda

Cuadro 8: Espacio de búsqueda del GridSearchCV para SVM

Hiperparámetro	Valores explorados	Descripción
`C`	0.1, 0.3, 1, 3, 10, 30, 100	Control de margen vs error de clasificación
`gamma`	`'scale'`, 0.01, 0.03, 0.1, 0.3, 1	Alcance del kernel RBF
`class_weight`	`None`, `'balanced'`	Compensación de desbalance de clases

5.2. Mejores configuraciones SVM

Cuadro 9: Mejores configuraciones SVM por escenario (top resultados del GridSearchCV)

Esc.	C	Gamma	class_weight	Recall CV	Std CV	Rank
A	0.1	1	None	1.0000	0.0000	1
A	0.1	1	balanced	1.0000	0.0000	1
A	0.3	1	None	0.9947	0.0105	3
B	3	scale	balanced	0.9735	0.0166	1
B	10	scale	balanced	0.9735	0.0236	1
B	10	0.3	balanced	0.9735	0.0236	1

5.3. Resultado central: base vs optimizado

Cuadro 10: SVM base vs optimizado – comparación completa de métricas en test

Esc.	Tipo	Recall CV	Recall Test	Prec. Test	F1 Test	AUC Test	FN	TN/FP/F
A	Base	0.9632	0.9574	0.9375	0.9474	0.9908	2	85/3/2/
A	Optimizado	**1.0000**	**1.0000**	0.9038	0.9495	0.9744	**0**	83/5/0/
B	Base	0.9418	0.9149	0.9348	0.9247	0.9877	4	85/3/4/
B	Optimizado	0.9735	0.9787	0.9388	0.9583	0.9705	1	85/3/1/

Resultado excepcional en Escenario A: el SVM optimizado logra Recall = 1.0000 y FN = 0 en el conjunto de prueba. Esto significa que **ningún caso maligno fue clasificado incorrectamente**. El costo de este logro es una caída en precisión de 0.9375 a 0.9038 (5 falsos positivos en lugar de 3) y en AUC de 0.9908 a 0.9744.

5.4. Diagnóstico de ajuste – SVM

Cuadro 11: Análisis de sobreajuste/subajuste – SVM optimizado

Esc.	Tipo	Recall train	Recall valid	Gap	Diagnóstico	Sostiene en test
A	Base	0.9749	0.9632	0.0117	Estable	Referencia
A	Optimizado	1.0000	1.0000	0.0000	Estable	Sí
B	Base	0.9458	0.9418	0.0040	Estable	Referencia
B	Optimizado	0.9762	0.9735	0.0026	Estable	Sí

El gap train-valid de SVM A optimizado es exactamente 0.0000, lo que podría interpretarse como indicio de sobreajuste. Sin embargo, el hecho de que *este mismo rendimiento se sostenga en test* descarta el sobreajuste clásico. La explicación es más matizada: el dataset presenta separabilidad alta y el kernel RBF con parámetros específicos ($C = 0{,}1$, $\gamma = 1$) encontró una frontera de decisión que cubre perfectamente todos los casos malignos. Este comportamiento es esperable en datasets bien condicionados con alta separación inter-clase.

6. Comparación Final: Todos los Modelos Optimizados

Cuadro 12: Ranking final de los seis candidatos optimizados (ordenado por Recall de maligna en test)

Esc.	Modelo	Recall CV	Recall Test	Prec. Test	F1 Test	AUC Test	FN	Sostiene
A	**SVM**	1.0000	**1.0000**	0.9038	0.9495	0.9744	**0**	Sí
A	LR	0.9789	0.9574	0.9375	0.9474	**0.9944**	2	Sí
B	SVM	0.9735	0.9787	0.9388	**0.9583**	0.9705	1	Sí
A	KNN	0.9632	0.9149	0.9348	0.9247	0.9889	4	No
B	LR	0.9471	0.9149	0.9348	0.9247	0.9920	4	No
B	KNN	0.9578	0.9149	0.9348	0.9247	0.9897	4	No

Lectura del ranking:

- **SVM A optimizado** domina en el criterio clínico principal (Recall, FN). Es el único candidato que elimina completamente los falsos negativos.
- **LR A optimizado** es el segundo mejor y el más fuerte en AUC (0.9944), lo que lo hace preferible si el contexto requiriera probabilidades bien calibradas.
- **KNN** en ningún escenario supera su baseline de forma consistente en test; queda descartado como modelo final.
- Los tres modelos del Escenario B que "no sostienen" en test (KNN-A, LR-B, KNN-B) exhiben una discordancia entre la mejora en CV y la no-mejora en test, señal de que el tuning no generalizó en esos casos.

7. Modelo Final Seleccionado

7.1. Selección

Modelo final: SVM optimizado con kernel RBF, Escenario A (todas las variables).

Parámetros finales: `C=0.1`, `gamma=1`, `kernel='rbf'`, `class_weight=None`, `StandardScaler`.

7.2. Justificación técnica

1. **Recall test = 1.0000:** máximo posible. Ningún caso maligno clasificado incorrectamente.
2. **FN test = 0:** criterio clínico dominante del proyecto.
3. **Sostiene en test:** la mejora observada en CV se confirma en el conjunto de prueba independiente.
4. **Sin sobreajuste clásico:** el gap train-valid de 0.0 se explica por separabilidad del dataset, no por memorización.

7.3. Cuantificación del trade-off clínico

Cuadro 13: Trade-off clínico: SVM A optimizado vs LR A optimizado (conjunto de prueba)

Modelo	TP (malignos detectados)	FN (omitidos)	FP (falsos alarmas)	AUC
SVM A optimizado	47	**0**	5	0.9744
LR A optimizado	45	2	3	0.9944
Diferencia	+2	−2	+2	−0,0200

SVM A evita 2 falsos negativos a cambio de 2 falsos positivos adicionales y 0.02 de AUC. En el contexto clínico: un falso negativo puede significar un cáncer no tratado; un falso positivo implica una biopsia adicional o seguimiento. La relación costo-beneficio es claramente favorable a SVM A desde la perspectiva médica.

8. Sesgo, Varianza y Estabilidad del Modelo Final

El análisis de sesgo-varianza del SVM A optimizado muestra:

- **Sesgo bajo:** el modelo clasifica correctamente la totalidad de los casos en validación (Recall CV = 1.0), indicando que tiene suficiente complejidad para aprender la estructura del problema.
- **Varianza baja:** la desviación estándar del Recall en CV es 0.0, lo que significa que los cinco folds obtuvieron exactamente el mismo resultado. Esto es posible porque el dataset tiene separabilidad alta y los 540 registros de entrenamiento son suficientes para que el modelo sea estable.
- **Generalización:** la transferencia perfecta de CV a test (Recall 1.0 en ambos) descarta memorización. Si hubiera sobreajuste, esperaríamos que el test degradara respecto al CV.

La estabilidad del modelo es también coherente con el contexto del dataset: alta separabilidad inter-clase, rangos acotados (1–10) y sin ruido severo hacen que la frontera de decisión sea robusta.

9. Verificación de Hipótesis de Semana 1

Cuadro 14: Estado de las hipótesis formuladas en el EDA al cierre de Semana 3

Hipótesis	**Veredicto**	**Eviden**
H1: Bare Nuclei y variables de uniformidad serán las más importantes	Confirmada parcialmente	El Escenario B con esas 3 variables alcanza Recall 0.979; el modelo final usa todas las variables
H2: Modelos no lineales capturan mejor relaciones	Confirmada	SVM-RBF supera a LR en Recall en ambos escenarios tras tuning

10. Conclusiones de Semana 3

1. El diseño experimental (split heredado, CV estratificada, mismo protocolo para todos los modelos) fue estable y comparable de inicio a fin.
2. **SVM con kernel RBF optimizado en Escenario A** es el modelo final: Recall = 1.0, FN = 0, sin evidencia de sobreajuste.
3. LR optimizada queda como alternativa fuerte para contextos donde se requiera AUC alto o probabilidades calibradas.
4. KNN no muestra mejora consistente tras tuning y no es un candidato viable para producción.
5. Las 5 hipótesis del EDA quedaron verificadas o confirmadas, cerrando la coherencia del proyecto desde Semana 1.
6. El trade-off del modelo final (2 FP adicionales a cambio de 0 FN) es clínicamente defendible y explícitamente cuantificado.

Repositorio del proyecto: https://github.com/AngelEsquit/PRY2-MD.git