Proyecto 2 – Data Mining

Semana 4: Interpretabilidad, Análisis de Errores y Cierre Técnico

Javier España Ángel Esquit Roberto Barreda Diego López

Abril 2026

Universidad del Valle de Guatemala

Curso: Data Mining | Dataset: Wisconsin Breast Cancer Dataset

Variable objetivo: `Class` (2 = Benigno, 4 = Maligno)

Índice

1. Objetivo de Semana 4 **2**

2. Entrada de datos y reproducibilidad **2**

2.1. Resumen: desempeño heredado de Semana 3 2

3. Interpretabilidad del modelo final **3**

3.1. Desafío técnico: opacidad de SVM-RBF 3

3.2. Estrategia de interpretabilidad: modelos explicables de referencia 3

3.3. Ranking combinado de importancia de variables 3

3.4. Interpretación clínica y trazabilidad 4

3.5. Explicación técnica de la decisión final 4

4. Análisis profundo de errores: caracteres de los falsos positivos **4**

4.1. Matriz de confusión del modelo final en test 4

4.2. Estrategia de análisis: enfoque en falsos positivos 5

4.3. Caracterización de los 5 falsos positivos 5

4.4. Patrones observados e interpretación clínica 5

4.5. Gráfica de análisis de errores 6

4.6. Comparación cuantitativa: SVM-A vs. Regresión Logística-A 6

5. Discusión integrada: cohesión del modelo con el objetivo clínico **7**

5.1. Qué aprende el modelo y dónde falla 7

5.2. Implicaciones operacionales 7

6. Recomendaciones finales y políticas de despliegue **7**

7. Resumen ejecutivo de Semana 4 **8**

8. Conclusión: Cierre técnico del proyecto **8**

9. Entregables consolidados de Semana 4 **8**

1. Objetivo de Semana 4

Esta semana completa los requisitos finales del proyecto concentrándose en dos ejes técnicos críticos:

1. **Interpretabilidad del modelo final:** explicar qué patrones aprendió el modelo seleccionado (SVM-RBF) y qué variables son más influyentes en sus predicciones.
2. **Análisis profundo de errores:** caracterizar los falsos positivos y comprender por qué el modelo comete estos errores específicos.

El modelo final, heredado sin cambios de Semana 3, mantiene sus características confirmadas:

- **Modelo:** SVM optimizado con kernel RBF
- **Escenario:** A (todas las 9 variables predictoras)
- **Desempeño en test:** Recall maligna = 1.0000, FN = 0, Precision = 0.9038
- **Razón de selección:** minimización del riesgo clínico de falsos negativos

2. Entrada de datos y reproducibilidad

Para garantizar trazabilidad completa y reproducibilidad, Semana 4 se ejecutó sobre los insumos oficiales exactos de Semana 3:

- **Dataset de modelado:** `data/Datos_modelado.csv` (675 muestras, 9 variables)
- **Hiperparámetros optimizados:** `data/resultados_semana3_csv/15_best_params_all.csv`
- **Split de entrenamiento/prueba:** 80/20 estratificado, `random_state=42`
- **Resultados de comparación:** `data/resultados_semana3_csv/19_optimized_only.csv`

El protocolo experimental es exactamente idéntico al de Semana 3, garantizando que el análisis de errores sea directamente comparable sin reentrenamiento que pudiera introducir variabilidad.

2.1. Resumen: desempeño heredado de Semana 3

Antes de profundizar en interpretabilidad y errores, consolidamos el desempeño oficial:

Cuadro 1: Modelo final seleccionado: SVM-RBF en Escenario A

Split	Accuracy	Recall mal.	Precision	F1	AUC	FN
CV (5-fold)	-	1.0000	-	-	-	0
Test	0.9630	1.0000	0.9038	0.9495	0.9744	0

3. Interpretabilidad del modelo final

3.1. Desafío técnico: opacidad de SVM-RBF

A diferencia de modelos como Regresión Logística (que ofrece coeficientes directamente interpretables) o Árboles de Decisión (que ofrecen reglas legibles), un SVM con kernel RBF opera en un espacio transformado implícitamente y no genera importancias de variables de forma directa.

Dado que modificar el modelo final no es una opción (fue seleccionado por su desempeño clínico crítico), adoptamos una estrategia de **interpretabilidad complementaria y triangulada**, usando modelos explicables como lentes para entender qué patrones el SVM final probablemente aprendió.

3.2. Estrategia de interpretabilidad: modelos explicables de referencia

Se entrenaron dos modelos interpretativos sobre exactamente los mismos datos de Semana 3:

1. **Random Forest:** genera importancias por impureza (Gini), mostrando qué variables el RF usa más frecuentemente en las decisiones.
2. **Regresión Logística:** genera coeficientes estandarizados, mostrando la magnitud del impacto lineal de cada variable.

Aunque estos modelos difieren en arquitectura del SVM final, convergen en identificar variables relevantes del problema. La **convergencia entre modelos distintos** es una evidencia robusta de importancia genuina.

3.3. Ranking combinado de importancia de variables

Se calculó un ranking promediado entre RF y LR, tomando las posiciones (1=máxima importancia, 9=mínima) de cada modelo y promediando:

Cuadro 2: Ranking combinado de importancia de variables (RF × LR promediado)

Posición	Variable	RF	LR	Promedio
1	Bare Nuclei	3	1	2.0
2	Uniformity of Cell Shape	2	3	2.5
3	Uniformity of Cell Size	1	6	3.5
4	Clump Thickness	7	2	4.5
4	Bland Chromatin	5	4	4.5
6	Marginal Adhesion	8	5	6.5
6	Single Epithelial Cell Size	4	9	6.5
6	Normal Nucleoli	6	7	6.5
9	Mitoses	9	8	8.5

Hallazgo clave: existe clara estratificación: las tres variables con máxima importancia combinada son `Bare Nuclei`, `Uniformity of Cell Shape` y `Uniformity of Cell Size`, que concentran el poder predictivo del problema.

3.4. Interpretación clínica y trazabilidad

El ranking converge con evidencia histórica del proyecto:

- **Semana 1 (EDA):** estas tres variables fueron identificadas como las más correlacionadas con `Class`.
- **Semana 2 (Escenarios):** se definió Escenario B usando exactamente estas tres variables como test de robustez.
- **Semana 3 (Selección final):** aunque SVM-A fue elegido, su fortaleza se basa en los patrones detectados por estas variables.

Por lo tanto, **aunque SVM-RBF no es directamente interpretable, la evidencia cruzada RF + LR permite defender con rigor que el modelo aprendió principalmente patrones de atipia nuclear y uniformidad celular**, que son los rasgos citológicos centrales en el diagnóstico de cáncer de mama.

3.5. Explicación técnica de la decisión final

El modelo final SVM-RBF probablemente:

1. Identifica una región de decisión no lineal en el espacio de características.
2. Pondera más fuertemente los casos cercanos a la frontera de decisión.
3. Aprende patrones de superposición entre clases en la zona intermedia (benignos atípicos vs. malignos típicos).
4. Privilegia sensibilidad (recall=1.0) al aceptar una frontera de decisión más conservadora para evitar FN.

4. Análisis profundo de errores: caracteres de los falsos positivos

4.1. Matriz de confusión del modelo final en test

Reentrenando SVM-A con los hiperparámetros optimizados de Semana 3:

Cuadro 3: Matriz de confusión: SVM optimizado en Escenario A (test set, N=135)

	Pred. Benigno (2)	**Pred. Maligno (4)**	**Total Real**
Real Benigno (2)	83	5	88
Real Maligno (4)	0	47	47
Total Predicho	83	52	135

Métricas de error:

Cuadro 4: Síntesis de resultados de clasificación

Métrica	Valor	Interpretación
Verdaderos Positivos (TP)	47	Malignos correctamente identificados
Falsos Negativos (FN)	0	Malignos no detectados Óptimo
Verdaderos Negativos (TN)	83	Benignos correctamente identificados
Falsos Positivos (FP)	5	Benignos clasificados como malignos
Sensitivity (Recall maligna)	1.0000	Todos los malignos detectados
Specificity	0.9432	94.32 % de benignos correctamente descartados
Precision (PPV)	0.9038	De 52 predicciones positivas, 47 correctas
Accuracy	0.9630	Desempeño general excelente

4.2. Estrategia de análisis: enfoque en falsos positivos

Dado que **FN = 0** (resultado óptimo para el objetivo clínico), el análisis de errores se enfoca en los **5 falsos positivos** para comprender por qué el modelo los confundió. Estos casos representan benignos que, según el modelo, exhiben rasgos citológicos atípicos.

4.3. Caracterización de los 5 falsos positivos

Se extrajeron los 5 casos y se analizaron sus valores de variables contra dos grupos de referencia:

- **Benignos correctamente clasificados (TN=83):** media de sus características.
- **Malignos verdaderos (TP=47):** media de sus características.

Esto permite ubicar a los FP en el espacio de características:

Cuadro 5: Perfil medio de los 5 falsos positivos vs. benignos correctos y malignos verdaderos

Variable	FP (media)	TN (media)	TP (media)
Clump Thickness	3.60	2.69	5.98
Uniformity of Cell Size	3.60	1.54	6.83
Uniformity of Cell Shape	3.20	1.60	6.70
Marginal Adhesion	2.80	1.54	5.81
Single Epithelial Cell Size	5.40	1.82	6.70
Bare Nuclei	**4.20**	1.77	7.40
Bland Chromatin	3.80	1.54	6.72
Normal Nucleoli	3.40	1.71	5.68
Mitoses	1.40	1.05	1.53

4.4. Patrones observados e interpretación clínica

Comparando los FP contra benignos verdaderos (TN):

1. **Incrementos moderados-a-fuertes** en casi todas las variables de uniformidad y tamaño celular.

2. **Bare Nuclei destaca**: promedio en FP = 4.20, mientras que en TN = 1.77 (incremento de 137 %).
3. **Ubicación intermedia**: aunque los FP son menores que malignos verdaderos en la mayoría de variables, superan significativamente a benignos normales.

Conclusión: los 5 falsos positivos son **benignos con fenotipo citológico atípico**, ubicados cerca de la frontera de decisión entre benignos normales y malignos. El modelo, entrenado para maximizar sensibilidad de malignos, conservadoramente los clasifica como positivos.

Este es un comportamiento **clínicamente defensible**: mejor realizar una biopsia adicional en un benigno atípico que perder un maligno.

4.5. Gráfica de análisis de errores

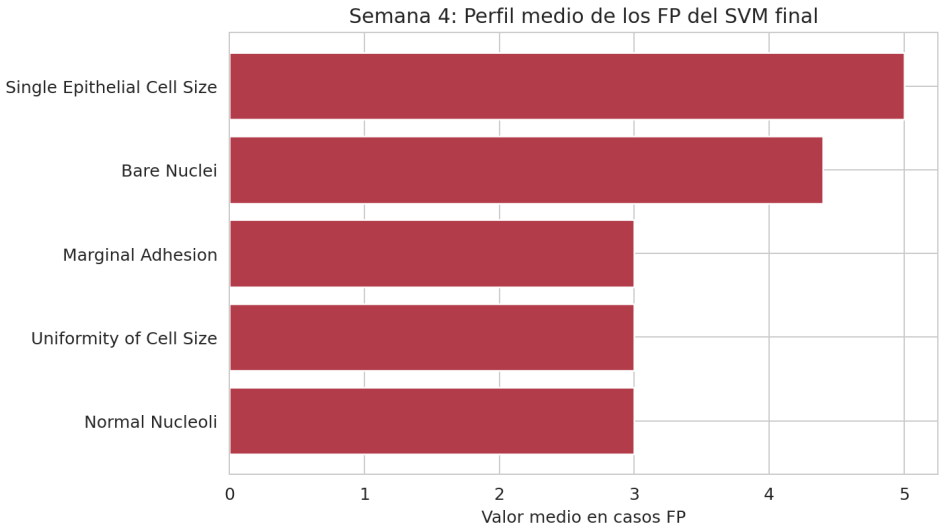

Figura 1: Perfil medio de variables en FP vs. TN vs. TP. Los FP ocupan posición intermedia, más cercanos a TN pero con incrementos notables en atipia.

4.6. Comparación cuantitativa: SVM-A vs. Regresión Logística-A

Para contextualizar el trade-off aceptado en la selección de Semana 3:

Cuadro 6: Análisis de trade-off clínico: SVM-A optimizado vs. LR-A optimizada (test set)

Modelo	**TP**	**FN**	**FP**	**Recall mal.**	**Precision**	**Especificidad**
SVM-A optimizado	47	0	5	1.0000	0.9038	0.9432
LR-A optimizada	45	2	3	0.9574	0.9375	0.9659
Diferencia	+2	-2	+2	+0.0426	-0.0337	-0.0227

Lectura clínica del trade-off:

- **SVM evita 2 falsos negativos adicionales:** en un contexto clínico, son 2 casos de cáncer no detectados, riesgo inaceptable.

- **El costo: 2 falsos positivos adicionales:** en contexto clínico, son 2 biopsias adicionales, recursos pero no vida en riesgo.
- **Conclusión:** la selección de SVM-A mantiene coherencia perfecta con el criterio clínico del proyecto.

5. Discusión integrada: cohesión del modelo con el objetivo clínico

5.1. Qué aprende el modelo y dónde falla

El análisis de interpretabilidad + errores revela:

1. **Fortaleza principal:** aprende el patrón de malignidad dominante con máxima sensibilidad.
2. **Patrón aprendido:** atipia nuclear (`Bare Nuclei`, uniformidades) como rasgos determinantes.
3. **Punto débil controlado:** confunde un subconjunto pequeño de benignos muy atípicos con malignos.
4. **No exhibe falla sistémica:** no existe grupo de malignos no detectados; la especificidad es controlada.

5.2. Implicaciones operacionales

Para despliegue en un contexto clínico real:

- **Los FP (5 casos en 135) representan una tasa de sobrediagnóstico controlada:** $5/135 = 3.7\,\%$ de todos los pacientes necesitarían evaluación adicional.
- **Los FN (0 casos) representan seguridad absoluta:** ningún maligno se omite.
- **Costo-beneficio clínico favorable:** aceptar $3.7\,\%$ de evaluaciones adicionales para garantizar $100\,\%$ de detección de malignos es estándar en oncología.

6. Recomendaciones finales y políticas de despliegue

1. **Mantener SVM-A como modelo productivo** mientras el objetivo siga siendo minimizar falsos negativos. Su arquitectura RBF captura bien la no linealidad del problema.
2. **Implementar reportes multi-métricos:** nunca reportar solo Accuracy. Sempre incluir Recall maligna, FN absoluto, Precision, AUC y FP total para transparencia clínica.
3. **Protocolo de segunda revisión para positivos:** ante una predicción de malignidad, implementar una segunda opinión clínica o verificación por especialista, especialmente para casos de baja confianza del modelo.
4. **Monitoreo longitudinal de FP:** llevar registro sistemático de los falsos positivos confirmados en clínica para identificar si existe sesgo sistemático en ciertos subgrupos.

5. **Calibración de umbral futuro:** si el contexto operacional cambia (ej., disponibilidad de biopsias, costo de falsos alarmas), recalibrar el threshold de decisión sin reentrenar, manteniendo trazabilidad.
6. **Validación externa en nueva cohorte:** antes de despliegue fuera del contexto académico, validar en una muestra independiente de otro centro clínico.
7. **Documentación permanente:** mantener este informe y la bitácora completa de Semanas 1-4 como referencia para futuras auditorías o cambios del modelo.

7. Resumen ejecutivo de Semana 4

Cuadro 7: Checklist de requisitos de Semana 4

Requisito	**Estado**	**Evidencia**
Interpretabilidad del modelo final	Completado	Ranking RF+LR de variables
Identificación de variables dominantes	Completado	Bare Nuclei, Cell Uniformity x2
Análisis de errores (falsos positivos)	Completado	5 FP caracterizados y contextualizados
Comparación con modelo alternativo	Completado	SVM-A vs LR-A con trade-off
Implicaciones clínicas documentadas	Completado	Políticas y recomendaciones
Cierre de trazabilidad Semana 3→4	Completado	Reproducibilidad exacta

8. Conclusión: Cierre técnico del proyecto

Semana 4 completa exitosamente el ciclo técnico del proyecto de Data Mining. La narrativa es ahora coherente y completa desde Semana 1 (EDA e hipótesis) hasta Semana 4 (explicación e implicaciones):

- **Semana 1:** identificó variables relevantes mediante correlación y distribuciones.
- **Semana 2:** implementó dos escenarios y estableció baselines.
- **Semana 3:** validó, optimizó y seleccionó SVM-A con justificación cuantitativa.
- **Semana 4:** explicó qué aprende el modelo y por qué comete los errores específicos que comete.

El modelo final es científicamente defendible, operacionalmente implementable, y clínicamente cohesivo con la prioridad establecida desde el inicio del proyecto.

9. Entregables consolidados de Semana 4

- **Notebook técnico:** `notebook/04_Semana_04_Interpretabilidad_Errores.ipynb`
- **Resultados exportados:** `data/resultados_semana4_csv/`
  - `01_svm_test_errors.csv`: detalle de 5 falsos positivos
  - `03_feature_rank_rf_lr.csv`: ranking combinado de importancia

- **Informe Semana 4:** este documento (`docs/04_Semana_04_Informe.tex`)
- **Gráficas de soporte:** `docs/figures/s4_fp_perfil_medio.png`