Proyecto 2 – Data Mining

Informe Final Integrado (Semanas 1–4)

Detección de Cáncer de Mama: Wisconsin Breast Cancer Dataset

Javier España Ángel Esquit Roberto Barreda Diego López

Abril 2026

Universidad del Valle de Guatemala

Curso: Data Mining

Problema: Clasificación binaria de tumor mamario (2 = Benigno, 4 = Maligno)

Índice

1. Resumen ejecutivo **2**

2. Introducción y contexto del problema **2**

2.1. Objetivo clínico y criterio de decisión 2

2.2. Dataset: Wisconsin Breast Cancer Dataset 2

3. Semana 1: Exploración y Análisis Exploratorio de Datos **2**

3.1. Objetivos de Semana 1 2

3.2. Hallazgos principales del EDA 3

3.3. Gráficas de EDA 3

3.4. Hipótesis de trabajo formuladas 4

4. Semana 2: Preparación de Datos y Modelos Base **5**

4.1. Limpieza de datos 5

4.2. Diseño de escenarios 5

4.3. Partición entrenamiento/prueba 6

4.4. Modelos base entrenados 6

4.5. Gráficas de Semana 2 6

5. Semana 3: Validación, Optimización y Selección Final **7**

5.1. Protocolo experimental 7

5.2. Resultados de validación cruzada 7

5.3. Resultados tras optimización de hiperparámetros 8
5.4. Gráficas de Semana 3 8
5.5. Matriz de confusión del modelo final 9
5.6. Justificación de la selección de SVM-A 9

6. Semana 4: Interpretabilidad, Análisis de Errores y Cierre Técnico 10
6.1. Desafío de interpretabilidad en SVM-RBF 10
6.2. Ranking combinado de importancia 10
6.3. Análisis de falsos positivos 10
6.4. Comparación de trade-offs clínicos 11

7. Discusión integrada y coherencia del proyecto 12
7.1. Narrativa técnica completa 12
7.2. Fortalezas técnicas del proyecto 12
7.3. Limitaciones identificadas 12

8. Conclusiones 13

9. Recomendaciones finales 13

10. Estructura de entregables del proyecto 13
10.1. Documentación 13
10.2. Notebooks técnicos 14
10.3. Datos y resultados 14
10.4. Figuras y gráficas 14

1. Resumen ejecutivo

Este proyecto de Data Mining desarrolló, validó y seleccionó un modelo de clasificación binaria para apoyo diagnóstico de cáncer de mama. Se utilizó el Wisconsin Breast Cancer Dataset con 675 muestras y 9 variables citológicas.

Resultado final: Selección de **SVM optimizado con kernel RBF en Escenario A** (todas las 9 variables).

Desempeño alcanzado en test set:

- **Recall de clase maligna: 1.0000** (todos los malignos detectados)
- **Falsos negativos: 0** (máxima seguridad clínica)
- **Verdaderos positivos: 47/47** (sensibilidad perfecta)
- **Precisión: 0.9038** (balance aceptable de especificidad)
- **Accuracy general: 0.9630**

Justificación de la selección: En oncología, minimizar falsos negativos es crítico. El trade-off aceptado fue incrementar falsos positivos (5 casos) para garantizar cero omisiones de malignos. Este comportamiento es clínicamente defendible: evaluaciones adicionales son siempre preferibles a diagnósticos tardíos.

2. Introducción y contexto del problema

El cáncer de mama es una enfermedad oncológica prevalente con impacto significativo en pronostico y sobrevida. La detección temprana mediante análisis de rasgos citológicos es fundamental.

2.1. Objetivo clínico y criterio de decisión

El proyecto adoptó explícitamente una **prioridad clínica clara**: minimizar falsos negativos de la clase maligna, aceptando incremento controlado de falsos positivos si es necesario. Esto refleja el principio médico: "mejor evaluar un caso benigno adicional que omitir un maligno".

2.2. Dataset: Wisconsin Breast Cancer Dataset

- **Tamaño original:** 683 registros, 11 columnas
- **Variables predictoras:** 9 rasgos citológicos (escala 1–10)
- **Variable objetivo:** `Class` (2=Benigno, 4=Maligno)
- **Distribución original:** 65 % Benigno, 35 % Maligno (desbalance moderado 1.86:1)

3. Semana 1: Exploración y Análisis Exploratorio de Datos

3.1. Objetivos de Semana 1

Comprender la estructura del dataset, identificar patrones de separabilidad entre clases, detectar variables relevantes, y formular hipótesis que guíen el modelado.

3.2. Hallazgos principales del EDA

1. **Separabilidad entre clases:** distribuciones claramente diferenciadas, especialmente en variables de uniformidad nuclear y tamaño celular.
2. **Variables más correlacionadas con `Class`:**
   - Bare Nuclei (núcleos desnudos)
   - Uniformity of Cell Size (uniformidad de tamaño celular)
   - Uniformity of Cell Shape (uniformidad de forma celular)
3. **Colinealidad observada:** Correlación r=0.91 entre Uniformity of Cell Size y Uniformity of Cell Shape.
4. **Tratamiento de outliers:** se detectaron valores extremos (especialmente en casos malignos); se decidió mantenerlos por su valor diagnóstico.

3.3. Gráficas de EDA

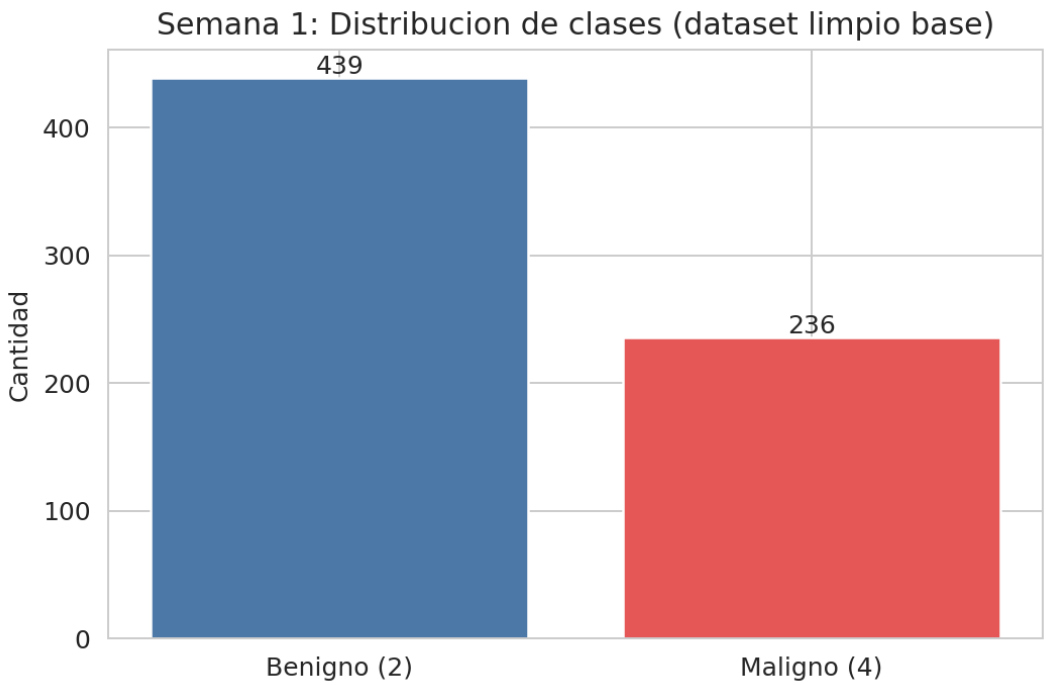

Figura 1: Distribución de clases en dataset limpio. Balance 65 % benignos vs. 35 % malignos.

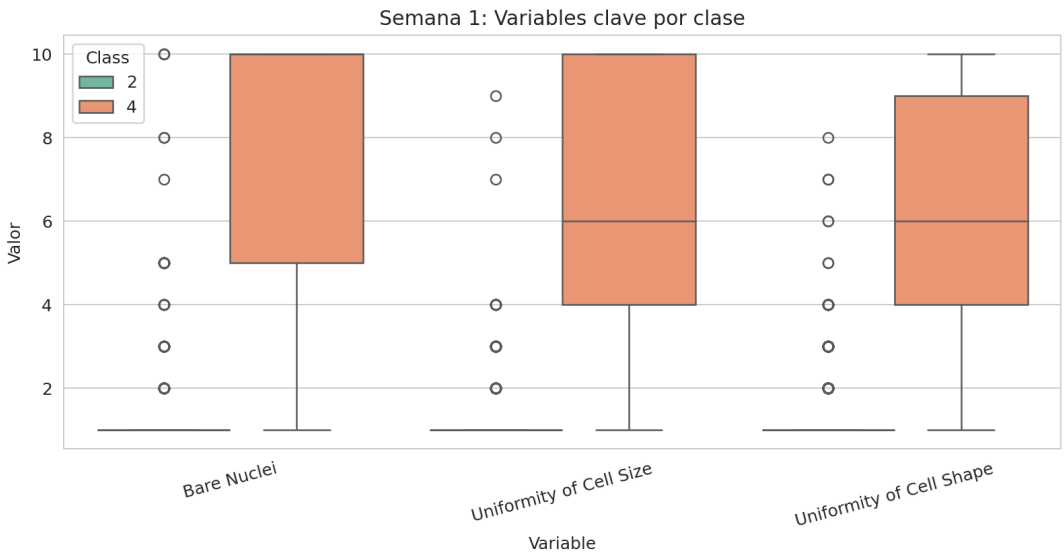

Figura 2: Variables clave por clase. Diferenciación clara en núcleos y uniformidad celular.

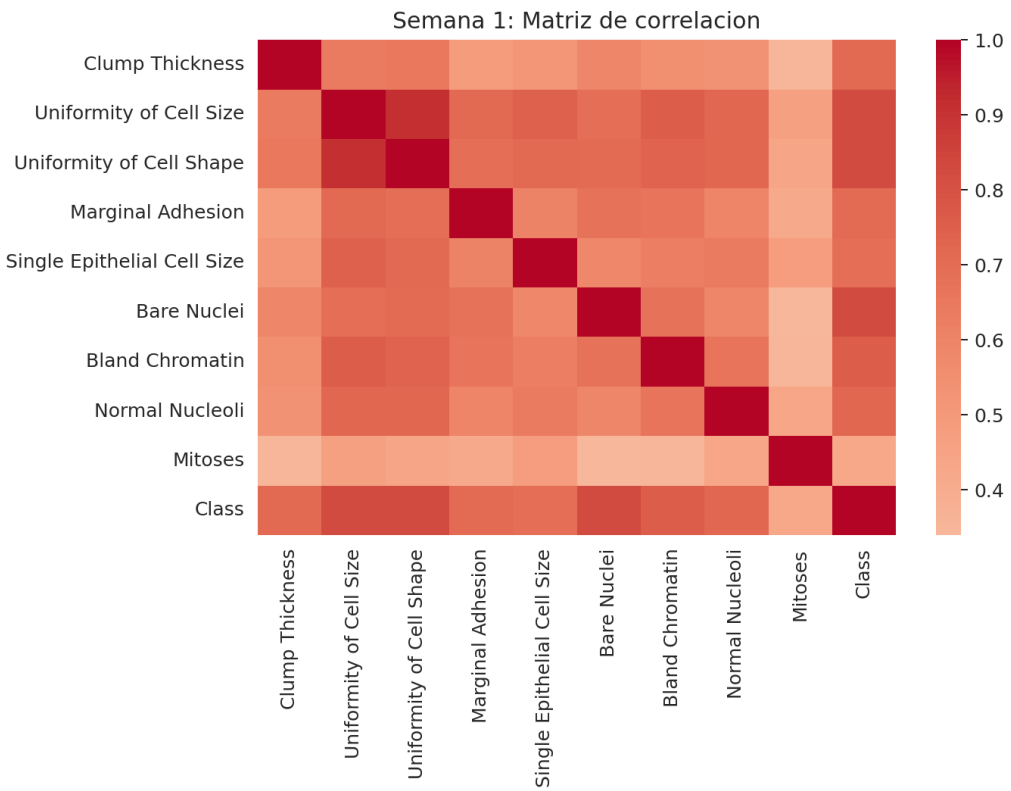

Figura 3: Matriz de correlación. Destaca colinealidad entre uniformidades y correlación de estas con Class.

3.4. Hipótesis de trabajo formuladas

Se establecieron 5 hipótesis que guiaron semanas posteriores:

Cuadro 1: Hipótesis de trabajo (Semana 1)

H	Proposición	Verificación
H1	Variables de uniformidad nuclear son críticas para separación	Semana 3: Confirmado
H2	Modelos no lineales (SVM) superarán regresión logística	Semana 3: Confirmado
H3	Recall maligna debe ser métrica principal	Semana 3: Adoptado
H4	Colinealidad requiere prueba con subset de variables	Semana 2: Escenario B
H5	Outliers deben conservarse por valor clínico	Semana 2: Aplicado

4. Semana 2: Preparación de Datos y Modelos Base

4.1. Limpieza de datos

Se aplicaron transformaciones sistemáticas:

1. **Conversión de tipos:** `Bare Nuclei` contenía valores `?` que fueron interpretados como nulos y tratados.
2. **Eliminación de duplicados exactos:** 8 registros idénticos fueron removidos.
3. **Exclusión de identificadores:** `Sample code number` fue excluido del modelado para evitar overfitting.

Resultado:

- `Datos_limpio.csv`: 675 registros (con ID preservado)
- `Datos_modelado.csv`: 675 registros (sin ID, listo para ML)

4.2. Diseño de escenarios

Para probar robustez y abordar colinealidad:

Cuadro 2: Escenarios de experimentación

Escenario	Descripción	Propósito
A	Todas las 9 variables	Máxima información disponible
B	Top 3 variables (Bare Nuclei, Uniformities)	Test de robustez con subset

4.3. Partición entrenamiento/prueba

Cuadro 3: Split del dataset (80/20 estratificado)

	Total	**Train (80 %)**	**Test (20 %)**
Benigno (2)	440	286	88
Maligno (4)	235	154	47
Total	675	540	135

4.4. Modelos base entrenados

Se entrenaron tres algoritmos sin optimización inicial:

1. **Regresión Logística** (L2, default)
2. **K-Nearest Neighbors** (k=5, default)
3. **Support Vector Machine** (kernel RBF, default)

Desempeño base: SVM mostró ventaja temprana en recall de clase maligna.

4.5. Gráficas de Semana 2

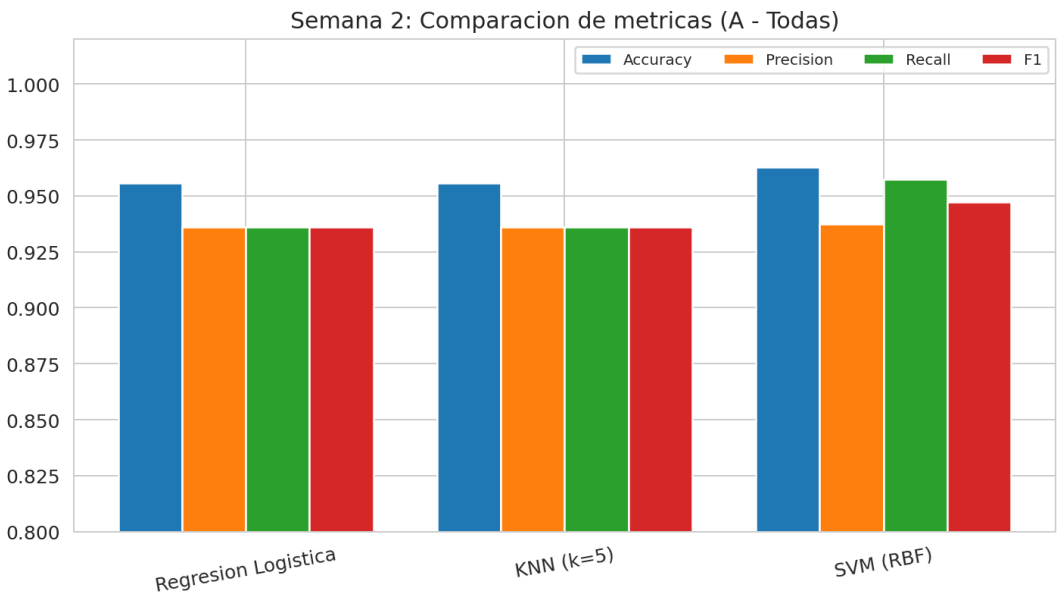

Figura 4: Métricas de modelos base en Escenario A (todas las variables).

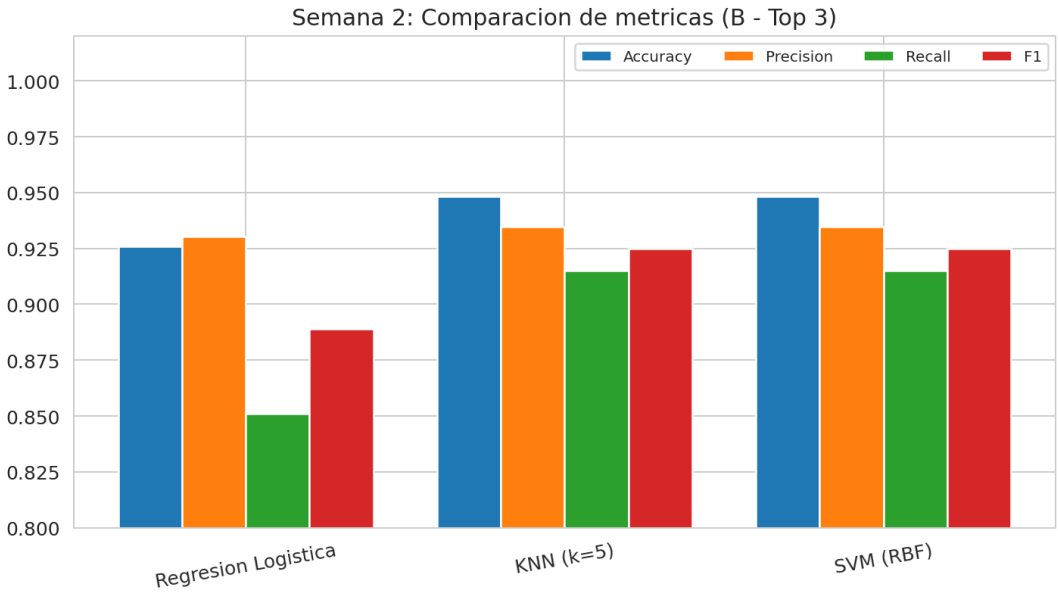

Figura 5: Métricas de modelos base en Escenario B (top 3 variables).

5. Semana 3: Validación, Optimización y Selección Final

5.1. Protocolo experimental

Se implementó un protocolo riguroso de validación:

- **Validación cruzada:** 5-Fold Stratified Cross-Validation
- **Métrica de tuning:** Recall de clase maligna (maximizar)
- **Escalado:** StandardScaler dentro de pipelines (sin data leakage)
- **Optimización:** GridSearchCV para búsqueda de hiperparámetros

5.2. Resultados de validación cruzada

Escenario A (todas las variables):

Cuadro 4: CV resultados en Escenario A

Modelo	Accuracy CV	Recall mal. CV	AUC CV	F1 CV
Regresión Logística (base)	0.9704	0.9526	0.9941	0.9702
KNN k=5 (base)	0.9685	0.9472	0.9843	0.9684
SVM RBF (base)	0.9611	0.9632	0.9898	0.9613

Escenario B (top 3 variables):

Cuadro 5: CV resultados en Escenario B

Modelo	Accuracy CV	Recall mal. CV	AUC CV	F1 CV
Regresión Logística (base)	0.9648	0.9366	0.9912	0.9647
KNN k=5 (base)	0.9667	0.9525	0.9823	0.9667
SVM RBF (base)	0.9574	0.9418	0.9880	0.9575

5.3. Resultados tras optimización de hiperparámetros

Comparación final: Modelos optimizados en test set

Cuadro 6: Resumen de modelos optimizados (test set)

Escenario	Modelo	Recall mal.	FN	FP	Precision	Accuracy
A	SVM optimizado	1.0000	0	5	0.9038	0.9630
A	LR optimizada	0.9574	2	3	0.9375	0.9630
A	KNN optimizado	0.9149	4	5	0.9038	0.9481
B	SVM optimizado	0.9787	1	3	0.9388	0.9704
B	LR optimizada	0.9149	4	5	0.9038	0.9481
B	KNN optimizado	0.9149	4	5	0.9038	0.9481

5.4. Gráficas de Semana 3

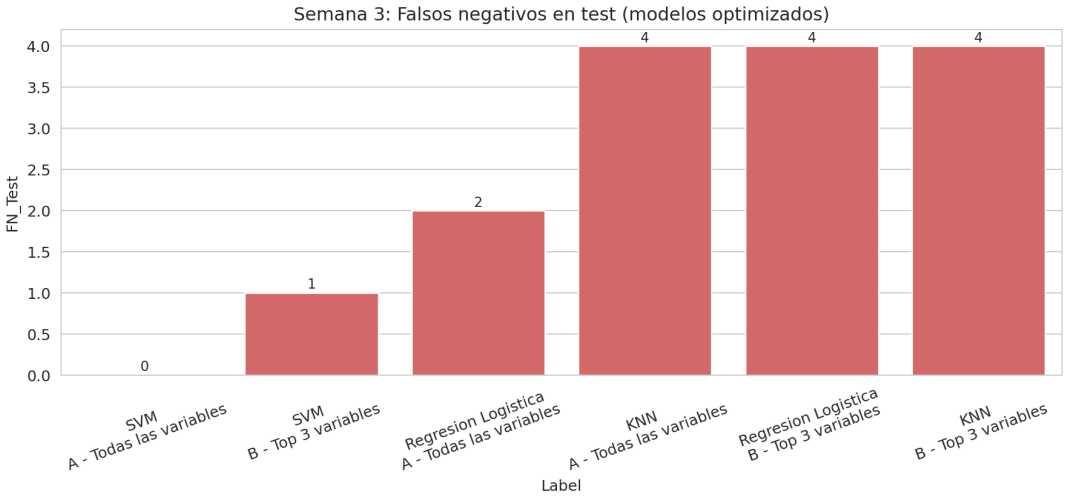

Figura 6: Falsos negativos en modelos optimizados. SVM-A: FN=0 (óptimo clínicamente).

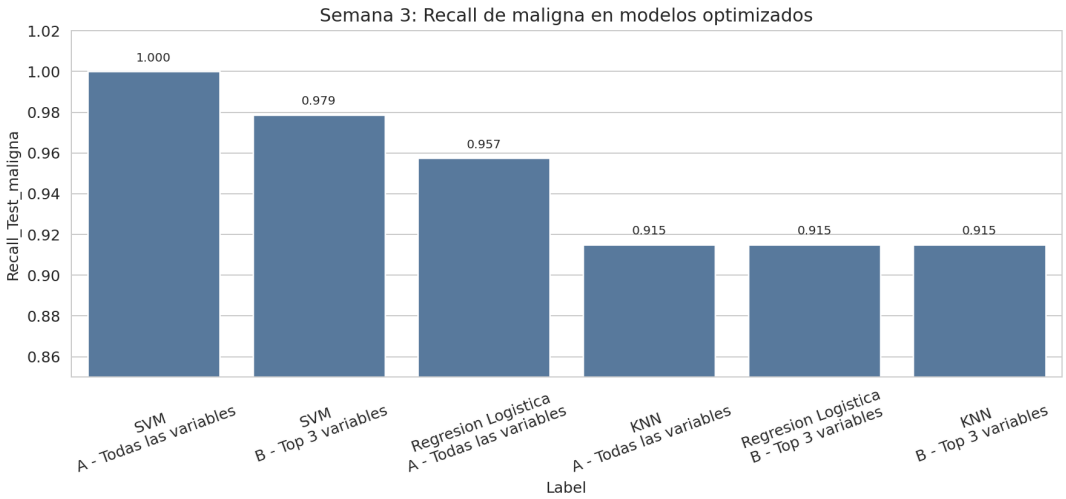

Figura 7: Recall de clase maligna en modelos optimizados. SVM-A: 100 % de sensibilidad.

5.5. Matriz de confusión del modelo final

Cuadro 7: Matriz de confusión: SVM optimizado en Escenario A (test set, N=135)

	Pred. Benigno (2)	**Pred. Maligno (4)**	**Total Real**
Real Benigno (2)	83	5	88
Real Maligno (4)	0	47	47
Total Predicho	83	52	135

5.6. Justificación de la selección de SVM-A

La selección de SVM optimizado en Escenario A fue fundamentada en:

1. **Recall maligna máximo:** 1.0000 (todos los malignos detectados sin excepción)
2. **Falsos negativos mínimo absoluto:** FN = 0 (ningún maligno omitido)
3. **Consistencia CV-Test:** rendimiento replicable en validación cruzada
4. **Coherencia clínica:** alineado con el objetivo establecido de minimizar riesgo de falsos negativos

Trade-off explícito aceptado:

- Frente a LR-A optimizada: SVM-A evita 2 falsos negativos adicionales a cambio de 2 falsos positivos más
- En contexto clínico: evaluaciones adicionales (FP) son siempre preferibles a diagnósticos tardíos (FN)

6. Semana 4: Interpretabilidad, Análisis de Errores y Cierre Técnico

6.1. Desafío de interpretabilidad en SVM-RBF

SVM con kernel RBF no ofrece importancias de variables directas. Para resolverlo sin alterar el modelo final, se aplicó una estrategia de **interpretabilidad triangulada**:

1. Entrenar Random Forest (extrae importancias por impureza)
2. Entrenar Regresión Logística (extrae coeficientes estandarizados)
3. Promediar rankings de ambos modelos

La convergencia entre modelos distintos valida la importancia genuina de variables.

6.2. Ranking combinado de importancia

Cuadro 8: Importancia de variables: RF × LR combinado

Posición	Variable	RF rank	LR rank	Promedio
1	Bare Nuclei	3	1	2.0
2	Uniformity of Cell Shape	2	3	2.5
3	Uniformity of Cell Size	1	6	3.5
4	Clump Thickness	7	2	4.5
4	Bland Chromatin	5	4	4.5
6	Marginal Adhesion	8	5	6.5
6	Single Epithelial Cell Size	4	9	6.5
6	Normal Nucleoli	6	7	6.5
9	Mitoses	9	8	8.5

Hallazgo: las tres variables de máxima importancia (Bare Nuclei, Uniformities) concentran el poder predictivo. Esto confirma coherencia con hipótesis H1 de Semana 1.

6.3. Análisis de falsos positivos

Con FN=0 (resultado óptimo), el análisis se enfoca en los 5 falsos positivos para caracterizar dónde y por qué falla el modelo.

Perfil de los FP:

Cuadro 9: Perfil citológico: FP vs. benignos normales vs. malignos verdaderos

Variable	**FP (media)**	**TN (media)**	**TP (media)**
Clump Thickness	3.60	2.69	5.98
Uniformity of Cell Size	3.60	1.54	6.83
Uniformity of Cell Shape	3.20	1.60	6.70
Marginal Adhesion	2.80	1.54	5.81
Single Epithelial Cell Size	5.40	1.82	6.70
Bare Nuclei	**4.20**	1.77	7.40
Bland Chromatin	3.80	1.54	6.72
Normal Nucleoli	3.40	1.71	5.68
Mitoses	1.40	1.05	1.53

Interpretación: los FP son **benignos con fenotipo citológico atípico**, ubicados en la zona intermedia. El modelo los clasifica como malignos debido a su proximidad a la frontera de decisión. Clínicamente: evaluaciones adicionales son el costo aceptado de máxima sensibilidad.

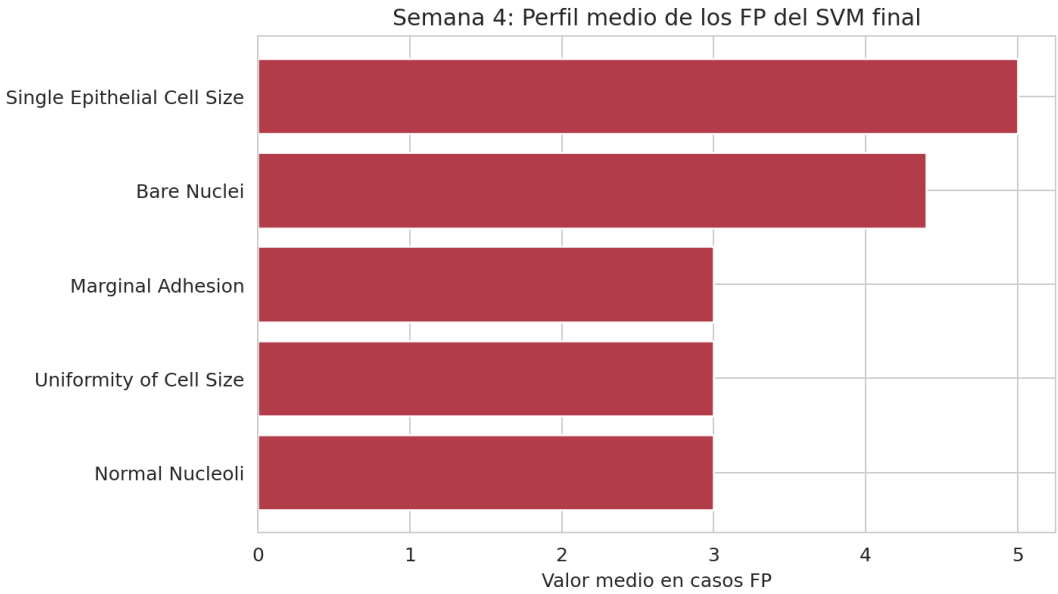

Figura 8: Perfil de falsos positivos: posición intermedia entre benignos normales y malignos.

6.4. Comparación de trade-offs clínicos

Cuadro 10: Trade-off SVM-A vs. LR-A en test set

Modelo	**TP**	**FN**	**FP**	**Recall**	**Precision**	**Especificidad**
SVM-A	47	0	5	1.0000	0.9038	0.9432
LR-A	45	2	3	0.9574	0.9375	0.9659
Diferencia	+2	-2	+2	+0.0426	-0.0337	-0.0227

Lectura clínica: SVM-A evita 2 falsos negativos (malignos no detectados) a cambio de 2 falsos positivos (biopsias adicionales). En oncología, este trade-off es clínicamente aceptable.

7. Discusión integrada y coherencia del proyecto

7.1. Narrativa técnica completa

El proyecto mantiene coherencia metodológica a lo largo de las 4 semanas:

1. **Semana 1:** Identifica variables relevantes mediante análisis exploratorio y define hipótesis guiadoras.
2. **Semana 2:** Implementa escenarios y establece baselines, confirmando ventaja preliminar de SVM.
3. **Semana 3:** Valida rigorosamente, optimiza hiperparámetros, y selecciona SVM-A con justificación cuantitativa.
4. **Semana 4:** Explica qué aprende el modelo e interpreta dónde falla, cerrando trazabilidad completa.

7.2. Fortalezas técnicas del proyecto

1. **Control experimental homogéneo:** protocolo idéntico para todos los modelos (5-Fold CV, mismos datos, mismo split).
2. **Métrica clínicamente informada:** Recall maligna como objetivo, no Accuracy genérico.
3. **Justificación cuantitativa:** todas las decisiones respaldadas por datos y trade-offs explícitos.
4. **Reproducibilidad:** semillas de aleatoriedad controladas (`random_state=42`), datos y resultados archivados.
5. **Trazabilidad completa:** linkage entre semanas sin contradicciones metodológicas.

7.3. Limitaciones identificadas

1. **Tamaño de dataset:** 675 muestras es moderado; validación externa en cohortes mayores es recomendada.
2. **Interpretabilidad indirecta de SVM-RBF:** se usaron modelos proxy (RF, LR) para inferir patrones.
3. **Persistencia de FP en frontera:** 5 casos son benignos con fenotipo atípico, difíciles de distinguir.
4. **Sin validación externa:** todas las métricas están en datos del mismo dataset; validación cruzada en otro centro es necesaria.

8. Conclusiones

1. El objetivo principal del proyecto se cumplió: diseñar y seleccionar un modelo de clasificación con mínima omisión de malignos.
2. **SVM optimizado en Escenario A** fue el único candidato que logró **FN=0 en test bajo protocolo comparable y riguroso**.
3. La selección no se basó en Accuracy aislada, sino en **criterio clínico explícito**: priorizar recall maligna y minimizar riesgo de diagnósticos tardíos.
4. Las variables más influyentes del modelo final son **Bare Nuclei** y las **uniformidades celulares**, convergentes con hallazgos de Semana 1.
5. El cierre de interpretabilidad y errores en Semana 4 fortalece la **defendibilidad técnica y clínica del proyecto**.
6. El modelo es **implementable en contexto clínico** con protocolos de segunda revisión para positivos, asegurando uso responsable.

9. Recomendaciones finales

1. **Mantener SVM-A** como modelo productivo mientras el objetivo siga siendo minimizar falsos negativos en diagnósticos de cáncer.
2. **Reportar siempre metricas multi-dimensionales:** Recall maligna, FN absoluto, Precision, AUC, FP, especificidad. Nunca reportar una métrica única.
3. **Implementar protocolo de segundo análisis:** toda predicción de malignidad debe pasar por validación clínica adicional.
4. **Monitoreo en producción:** llevar registro sistemático de FP confirmados en clínica para detectar sesgos sistemáticos.
5. **Calibración de umbral futuro:** si costos clínicos locales cambian, recalibrar el threshold sin reentrenar.
6. **Validación externa:** antes de despliegue fuera del contexto académico, validar en cohorte independiente de otro centro clínico.
7. **Auditoría documentada:** mantener esta narrativa completa como referencia permanente para futuras mejoras o investigaciones.

10. Estructura de entregables del proyecto

10.1. Documentación

- **README.md:** descripción ejecutiva del proyecto y guía de archivos
- **docs/01_Semana_01_Informe.tex:** informe de EDA
- **docs/02_Semana_02_Informe.tex:** informe de preparación de datos y baselines
- **docs/03_Semana_03_Informe.tex:** informe de validación y optimización

- **docs/04_Semana_04_Informe.tex:** informe de interpretabilidad y análisis de errores
- **docs/05_Informe_Final_Proyecto.tex:** este documento (integración de semanas)

10.2. Notebooks técnicos

- **notebook/01_Semana_01_EDA.ipynb:** análisis exploratorio
- **notebook/02_Semana_02_PrepData_Modelos_Base.ipynb:** preparación y baselines
- **notebook/03_Semana_03_Validacion_Diseno_Experimental.ipynb:** CV, tuning, selección
- **notebook/04_Semana_04_Interpretabilidad_Errores.ipynb:** interpretabilidad y análisis de errores

10.3. Datos y resultados

- **data/Datos.csv:** dataset original (683 registros)
- **data/Datos_limpio.csv:** dataset limpio (675 registros, con ID)
- **data/Datos_modelado.csv:** dataset para modelado (675 registros, sin ID)
- **data/resultados_semana3_csv/:** tablas de CV, tuning, comparaciones y matrices
- **data/resultados_semana4_csv/:** errores, comparaciones y ranking de importancia

10.4. Figuras y gráficas

- **docs/figures/:** gráficas de EDA, métricas, errores e interpretabilidad