UVG
UNIVERSIDAD DEL VALLE DE GUATEMALA

Semestre I del 2026

Proyecto #2 – Data Mining (PBL)

🎯 Objetivo general

Desarrollar un proyecto completo de minería de datos donde el estudiante:

- Analice un conjunto de datos real
- Formule un problema (sin que se le diga cuál)
- Construya, compare y evalúe modelos
- Justifique decisiones técnicas
- Comunique resultados de forma profesional

🧠 Conjunto de datos

Se les entrega el archivo: `Datos.csv`

📦 Estructura del proyecto (4 semanas)

📅 Semana 1 – Comprensión del problema + EDA

🎯 Objetivo

Que los estudiantes descubran:

- Qué representa el conjunto de datos
- Qué problema pueden resolver
- Primer análisis exploratorio

📌 Entregables

1. **Documento breve (3–5 páginas):**

- Descripción del conjunto de datos (variables, tipos)
- Identificación del problema:
  - ¿Clasificación o regresión?
  - ¿Variable objetivo?
- Análisis exploratorio:
  - Distribuciones
  - Correlaciones
  - Datos atípicos (Outliers)
- Hipótesis iniciales

2. **Notebook (EDA):**
   - Visualizaciones (mínimo 5)
   - Comentarios interpretativos

📊 Rúbrica – Semana 1 (20 pts)

Criterio	Puntos
Identificación correcta del problema	5
Calidad del EDA (visualizaciones + interpretación)	7
Comprensión de variables	4
Claridad del documento	4

📅 Semana 2 – Preparación de datos + Modelos base

🎯 Objetivo

Construir primeros modelos sin optimización

📌 Contenido esperado

- Limpieza de datos (si aplica)
- Selección de variables
- Train/Test split
- Modelos base (mínimo 3)

📌 Entregables

1. **Notebook:**
    - Preprocesamiento
    - Modelos base
    - Métricas:
        - Exactitud (Accuracy)
        - Precisión, Recall, F1
        - Matriz de confusión
2. **Documento (2–3 páginas):**
    - Justificación de modelos elegidos
    - Comparación inicial

📊 Rúbrica – Semana 2 (25 pts)

Criterio	Puntos
Correcto preprocesamiento	6
Implementación de modelos	8
Uso de métricas adecuadas	6
Interpretación de resultados	5

📅 Semana 3 – Mejora de modelos + Selección

🎯 Objetivo

Optimizar modelos y seleccionar el mejor

📌 Contenido esperado

- Cross-validation
- Afinación de Hiperparámetros (Hyperparameter tuning)
- Comparación formal de modelos
- Sobre ajuste vs Sub ajuste (Overfitting vs underfitting)

📌 Entregables

1. **Notebook:**
    - Modelos optimizados
    - Comparación clara
2. **Documento (3–4 páginas):**
    - Justificación del modelo final

- Discusión técnica:
  - Sesgo/varianza (Bias/variance)
  - Trade-offs

📊 Rúbrica – Semana 3 (30 pts)

Criterio	Puntos
Uso correcto de validación	8
Optimización de modelos	8
Comparación rigurosa	7
Justificación técnica	7

📅 Semana 4 – Interpretación + Presentación final

🎯 Objetivo

Comunicar resultados como un científico de datos

📌 Contenido esperado

- Interpretabilidad:
  - Importancia de características (Feature importance) (RF / árboles)
  - Coeficientes (logística)
- Análisis de errores
- Conclusiones
- Recomendaciones

📌 Entregables

1. 📄 Informe final (8–12 páginas)

Debe incluir:

- Introducción
- Metodología
- Resultados
- Discusión
- Conclusiones

---

2. 💻 Presentación (10–15 min)

- Problema
- Enfoque
- Modelo final
- Resultados clave

📊 Rúbrica – Semana 4 (25 pts)

Criterio	Puntos
Interpretación del modelo	7
Calidad del informe	8
Claridad de la presentación	5
Rigor técnico	5

Evaluación total

Semana	Puntos
Semana 1	20
Semana 2	25
Semana 3	30
Semana 4	25
Total	**100**

Reglas del proyecto

- Trabajo en grupos de 4 estudiantes
- Uso libre de librerías (sklearn, pandas, etc.)
- **Prohibido copiar notebooks completos**
- Se evaluará **explicación, no solo código**