Proyecto #2 – Data Mining (PBL)

Semana 1: Comprension del Problema + EDA

Deteccion de Cancer de Mama

Wisconsin Breast Cancer Dataset

Universidad del Valle de Guatemala

Semestre I – 2026

Integrantes

Javier España #23361

Angel Esquit #23221

Roberto Barreda #23354

Diego Lopez #23747

1. Descripcion del Conjunto de Datos

El archivo Datos.csv contiene 682 registros de biopsias de aspiracion con aguja fina (FNA) de masas mamarias. Cada registro representa una muestra celular evaluada por un patologo, con 9 caracteristicas citologicas puntuadas de 1 a 10, mas una variable de clase que indica si el tumor es benigno o maligno.

Este dataset corresponde al Wisconsin Breast Cancer Dataset, ampliamente utilizado en investigacion de aprendizaje automatico para problemas de clasificacion binaria en el ambito medico.

1.1 Variables del Dataset

Variable	Tipo	Rango	Descripcion
Sample code number	ID (entero)	—	Identificador unico de la muestra
Clump Thickness	Numerica ordinal	1–10	Grosor de agrupamiento celular
Uniformity of Cell Size	Numerica ordinal	1–10	Uniformidad en tamano celular
Uniformity of Cell Shape	Numerica ordinal	1–10	Uniformidad en forma celular
Marginal Adhesion	Numerica ordinal	1–10	Adhesion marginal
Single Epithelial Cell Size	Numerica ordinal	1–10	Tamano de celula epitelial
Bare Nuclei	Numerica ordinal	1–10	Nucleos desnudos
Bland Chromatin	Numerica ordinal	1–10	Cromatina blanda
Normal Nucleoli	Numerica ordinal	1–10	Nucleolos normales
Mitoses	Numerica ordinal	1–10	Conteo de mitosis
Class	Categorica binaria	2 o 4	2 = Benigno, 4 = Maligno

2. Identificacion del Problema

2.1 Tipo de Problema

Tipo: Clasificacion binaria supervisada.

El objetivo es predecir si un tumor mamario es benigno (Clase 2) o maligno (Clase 4) a partir de las 9 caracteristicas citologicas obtenidas de la biopsia FNA. Este es un problema clasico de clasificacion binaria donde se busca asignar cada muestra a una de dos categorias mutuamente excluyentes.

2.2 Variable Objetivo

Variable objetivo: Class

Esta variable toma dos valores: 2 (benigno, 444 muestras – 65.0%) y 4 (maligno, 239 muestras – 35.0%). Existe un desbalance moderado a favor de la clase benigna, lo cual debera considerarse al seleccionar metricas de evaluacion.

2.3 Relevancia del Problema

La deteccion temprana del cancer de mama es crucial para mejorar la tasa de supervivencia. Un modelo predictivo preciso podria asistir a los patologos en el diagnostico, reduciendo falsos negativos (tumores malignos no detectados) que son especialmente peligrosos en este contexto clinico.

3. Analisis Exploratorio de Datos (EDA)

3.1 Distribucion de la Variable Objetivo

La siguiente grafica muestra la distribucion de clases en el dataset. Se observa un desbalance moderado: 444 casos benignos (65%) frente a 239 malignos (35%). Aunque no es extremo, este desbalance sugiere que metricas como Precision, Recall y F1-Score seran mas informativas que la exactitud (accuracy) sola.

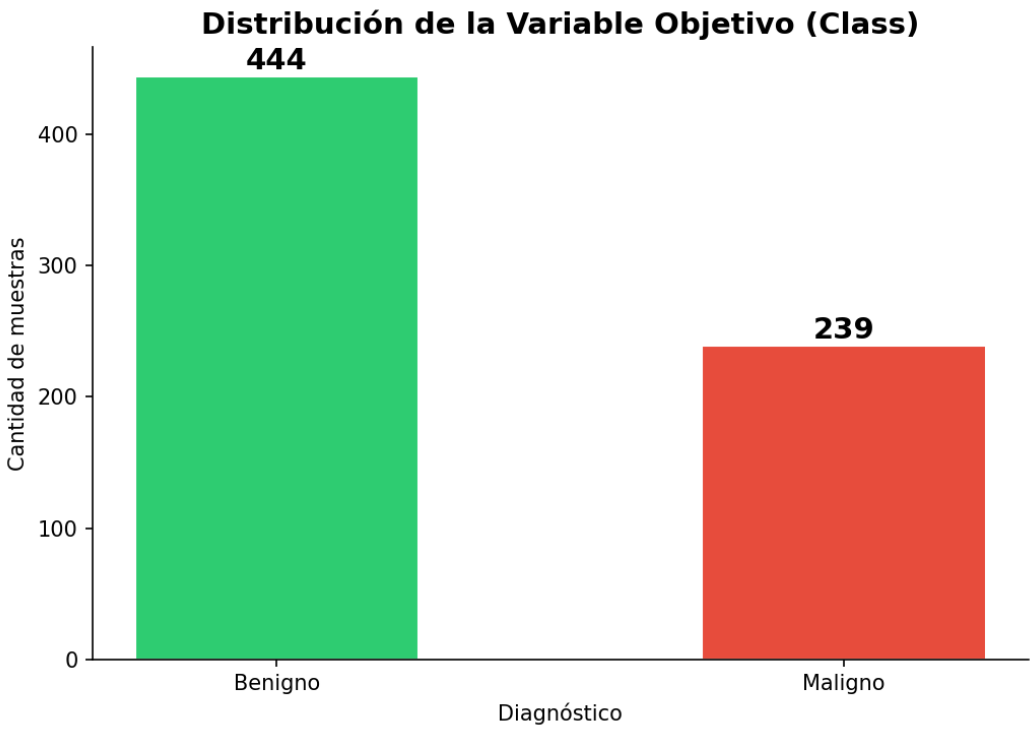

3.2 Distribuciones de Caracteristicas por Clase

Los histogramas muestran como se distribuyen las 9 caracteristicas segun el diagnostico. En las muestras benignas, la mayoria de caracteristicas se concentran en valores bajos (1–3), mientras que las muestras malignas presentan distribuciones mas dispersas con valores mas altos. Esta separacion es especialmente marcada en Uniformity of Cell Size, Uniformity of Cell Shape y Bare Nuclei, lo que sugiere alto poder discriminativo.

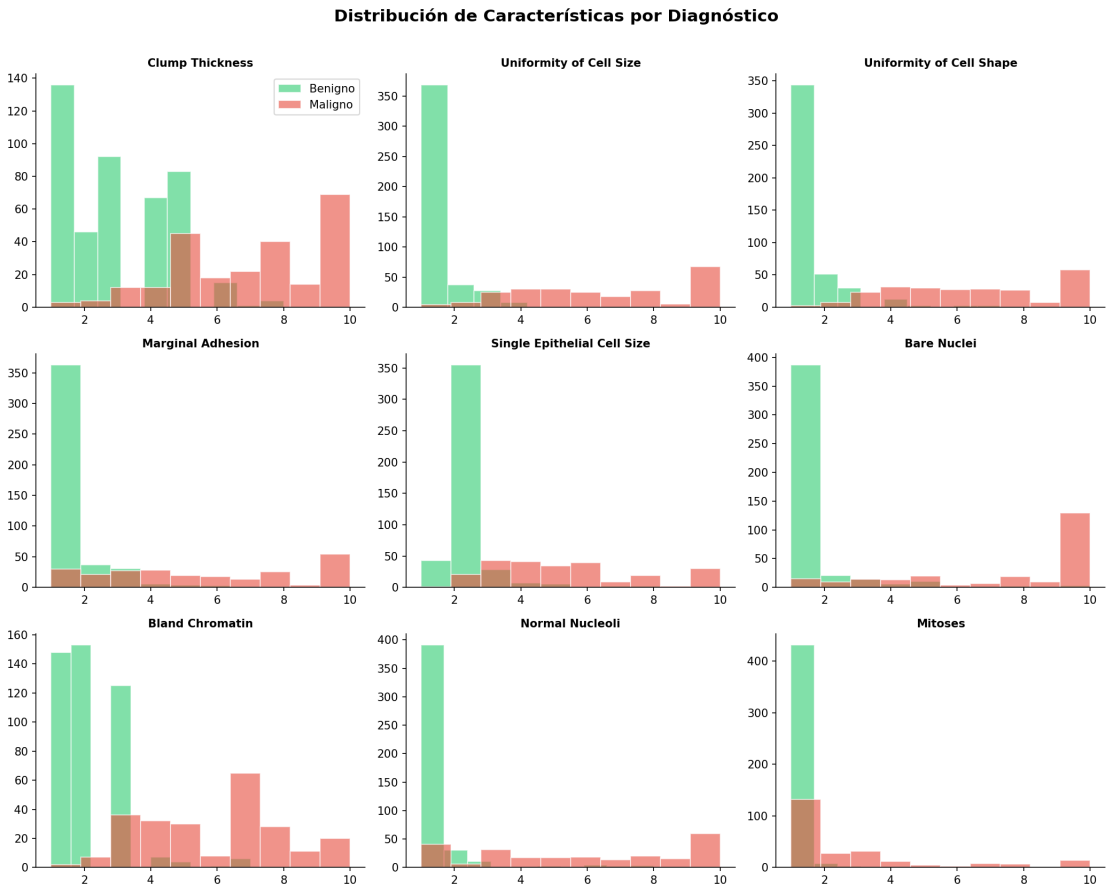

3.3 Matriz de Correlacion

La matriz de correlacion revela fuertes asociaciones entre varias caracteristicas y la variable objetivo. Bare Nuclei (r=0.82), Uniformity of Cell Shape (r=0.82) y Uniformity of Cell Size (r=0.82) son las mas correlacionadas con la clase. Tambien se observa multicolinealidad entre Uniformity of Cell Size y Uniformity of Cell Shape (r=0.91), lo cual podria afectar modelos lineales.

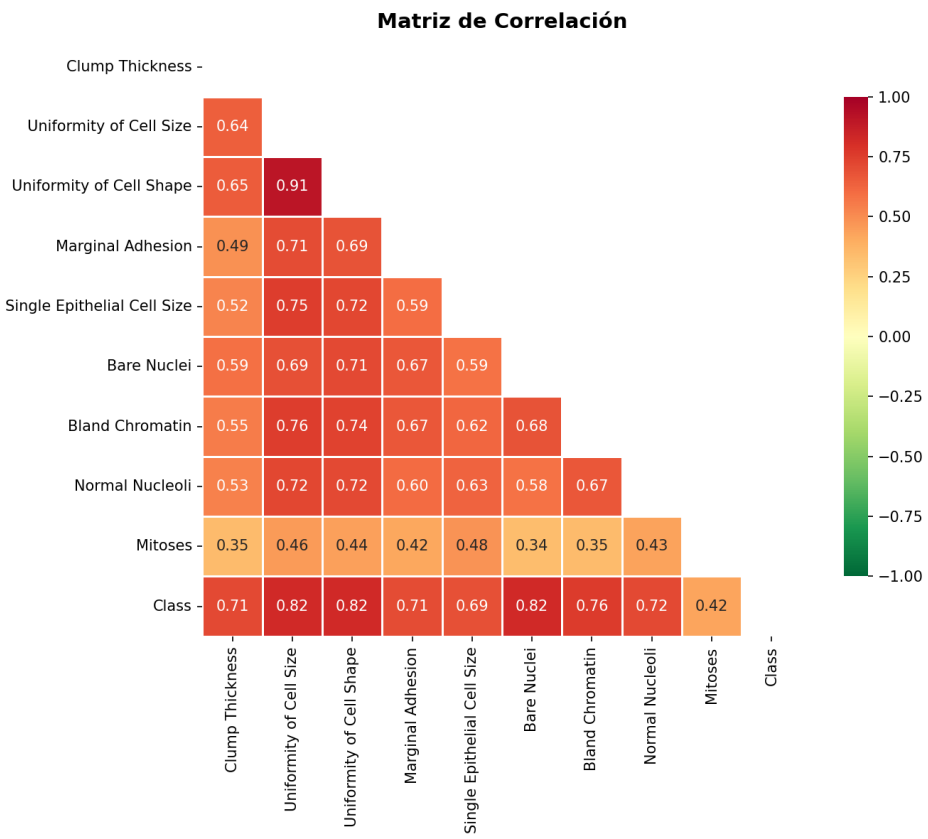

3.4 Deteccion de Outliers (Boxplots)

Los boxplots por clase permiten identificar datos atipicos. Las variables con mayor cantidad de outliers son Mitoses (120), Normal Nucleoli (75) y Marginal Adhesion (59). Estos outliers corresponden mayormente a casos malignos con valores extremos, lo cual es clinicamente consistente: tumores agresivos suelen presentar caracteristicas celulares anormales mas pronunciadas.

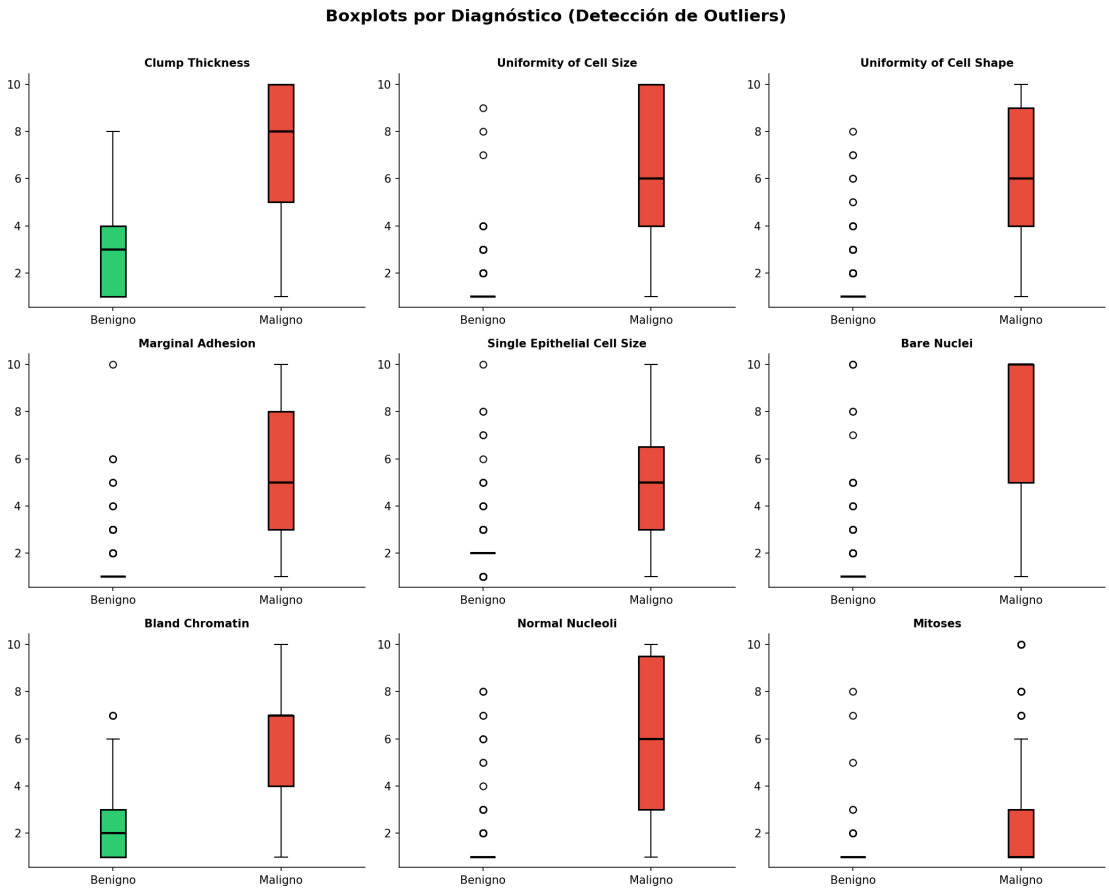

3.5 Comparacion de Medias por Diagnostico

El heatmap de medias confirma cuantitativamente lo observado en los histogramas. Las muestras malignas tienen promedios significativamente mas altos en todas las caracteristicas, especialmente en Bare Nuclei (benigno: 1.35 vs maligno: 7.63), Uniformity of Cell Size (1.32 vs 6.57) y Uniformity of Cell Shape (1.44 vs 6.56).

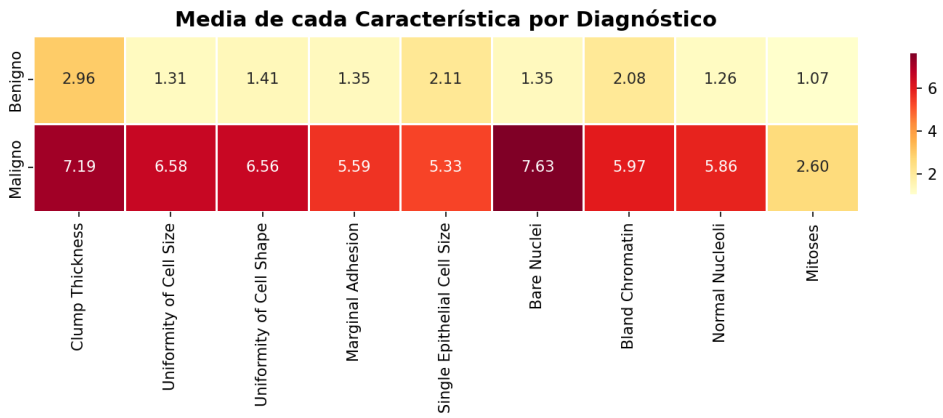

3.6 Pairplot de las 4 Variables Mas Discriminativas

El pairplot de Bare Nuclei, Uniformity of Cell Shape, Uniformity of Cell Size y Bland Chromatin muestra una clara separacion entre ambas clases en el espacio bidimensional. Los tumores benignos se agrupan en la esquina inferior izquierda (valores bajos), mientras que los malignos se dispersan hacia valores mas altos. Esta separabilidad sugiere que modelos de clasificacion deberian lograr un buen rendimiento.

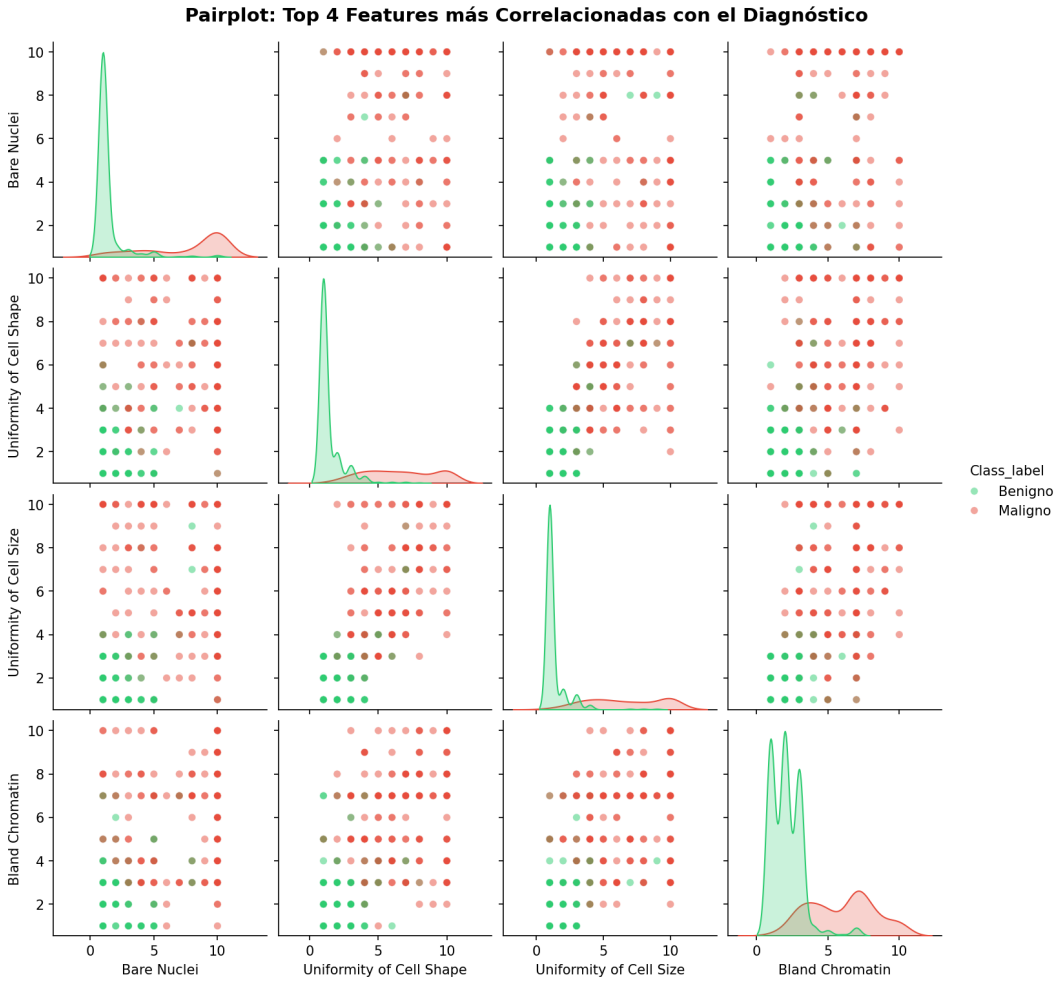

4. Hipotesis Iniciales

Con base en el analisis exploratorio realizado, se formulan las siguientes hipotesis:

- **H1:** Las variables Bare Nuclei, Uniformity of Cell Size y Uniformity of Cell Shape seran las mas importantes para la prediccion, dado su alto nivel de correlacion ($r > 0.82$) con la variable objetivo.
- **H2:** Un modelo basado en arboles de decision (como Random Forest) capturara mejor las relaciones no lineales entre las caracteristicas, superando a modelos

lineales.

- **H3:** El Recall de la clase maligna sera la metrica mas critica a optimizar, ya que un falso negativo (no detectar un tumor maligno) tiene consecuencias clinicas mas graves que un falso positivo.
- **H4:** La multicolinealidad entre Uniformity of Cell Size y Cell Shape (r=0.91) podria causar inestabilidad en los coeficientes de regresion logistica, favoreciendo tecnicas de regularizacion.
- **H5:** Los outliers detectados en Mitoses y Normal Nucleoli no deben eliminarse, ya que representan casos clinicamente relevantes (tumores agresivos) que el modelo necesita aprender a clasificar.